

A thick black L-shaped frame is positioned around the text. It starts at the top left, goes right, then down, then right again, forming a large 'L' shape that frames the text on the left and bottom.

ŠTATISTICKÁ ANALÝZA DÁT V R

Literatúra

- Kalina, M., Bacigál, T., Schiesslová, A.: Základy pravdepodobnosti a matematickej štatistiky, STU Bratislava, 2009
- Nánásiová O., Kohnová, S.: Štatistika a pravdepodobnosť. STU Bratislava, 2016
- Varga, Š.: Matematická štatistika, STU Bratislava, 2012
 - <https://bookdown.org/content/8ab7947b-f480-4e49-a28c-32c1970beb76/>
 - <https://r4ds.had.co.nz/index.html> (R for Data Science)
 - https://www.math.muni.cz/~kolacek/vyuka/vypsyst/navod_R.pdf
 - <https://aved.econ.muni.cz/>
 - https://www.researchgate.net/profile/Dagmar-Markechova/publication/313724644_Statistical_Methods_and_their_Applications/links/58a4293592851ce3473d7e0b/Statistical-Methods-and-their-Applications.pdf

Dáta, štatistická analýza dát

- V súčasnosti sa vytvára a spravuje veľké množstvo digitálnych údajov.
- Dátové súbory sa cielene zhromažďujú a ukladajú v elektronickej podobe.
- Obrovské objemy údajov (Big Data) vyžadujú systematickú analýzu a správnu interpretáciu výsledkov.
- Štatistická analýza dát je interdisciplinárna disciplína, ktorá pomocou matematicko-štatistických metód odhaľuje skryté závislosti, popisuje vlastnosti dát a umožňuje robiť závery nad pozorovanými javmi.

Štatistická analýza dát

- Štatistická analýza dát spája a využíva poznatky z odborov:
 - *Dátové inžinierstvo a informatika:* Efektívny zber, úprava, správa a spracovanie rozsiahlych dátových súborov.
 - *Data mining – hĺbková analýza dát:* Techniky a algoritmy na vyhľadávanie skrytých vzorov, štruktúr a poznatkov v dátach.
 - *Machine Learning – strojové učenie:* Využitie dát na trénovanie modelov, predikciu budúceho vývoja a automatizáciu rozhodovania.
 - *Matematická štatistika:* Teoretické základy, pravdepodobnostné modelovanie, testovanie hypotéz a odborná interpretácia výsledkov

Jazyk R v štatistickej analýze

- Špičkový nástroj pre štatistiku: Navrhnutý špeciálne pre štatistickú analýzu, pravdepodobnostné modelovanie a prácu s dátami.
- Bohatý ekosystém balíkov (CRAN, Comprehensive R Archive Network): Obsahuje desaťtisíce špecializovaných knižníc pre data mining, testovanie hypotéz a časové rady (napr. *ggplot2*, *dplyr*, *caret*).
- Pokročilá vizualizácia: Umožňuje vytvárať profesionálne grafy, reprezentácie pravdepodobnostných rozdelení a prehľadné dátové reporty.
- Prepojenie so strojovým učením a API: Zvláda zber dát cez REST API, predspracovanie pre AI modely a integráciu s Pythonom či databázami.

Experiment a pokus

Náhodný experiment - experiment, ktorého výsledok nemožno s istotou predpovedať, aj keď ho opakujeme presne za rovnakých podmienok

- Opakované posielanie požiadavky na API a meranie času jej odozvy

Náhodný pokus (pokús) - jedna konkrétna realizácia (vykonanie) náhodného experimentu

- Jedno konkrétne poslanie požiadavky a nameranie času odozvy (napr. 140ms)

V náhodnom experimente ovplyvňujú výsledok kontrolovateľné aj nekontrolovateľné faktory

Experiment a pokus

Kontrolovateľné faktory:

- Veľkosť posielaných dát
- Typ požiadavky

Nekontrolovateľné faktory:

- Aktuálne vyťaženie servera
- Rýchlosť internetového pripojenia
- Záťaž siete

Základné pojmy z teórie pravdepodobnosti

- Elementárna udalosť – výsledok náhodného pokusu, označenie $e_i(\omega_i)$.
- Elementárna udalosť pri hode kockou - padnutie čísla 1 až 6, napr. $e_i = 3$.
- Výberový priestor – množina všetkých možných výsledkov pokusu, označenie Ω :

- *Hod kockou*

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

- *Sieťová latencia, meranie času spiatočnej cesty (napr. v milisekundách)*

$$\Omega = [0, \infty)$$

- *Sieťová latencia, meranie stavu latencie*

$$\Omega = \{\text{nízka latencia, stredná latencia, vysoká latencia}\}$$

- *Monitorovanie straty paketov (napríklad v percentách)*

$$\Omega = [0, 100]$$

Základné pojmy teórie pravdepodobnosti

- Náhodná udalosť – ľubovoľná podmnožina A množiny Ω , $A \subseteq \Omega$.
- Istá udalosť – množina Ω .
- Nemožná udalosť – prázdna množina $\emptyset$.
- Príklady náhodných udalostí:
 - *Hod kockou – padlo párne číslo, $A = \{2, 4, 6\}$*
 - *Hod dvomi kockami – padol súčet tri, $A = \{(1,2), (2,1)\}$*
 - *Sieťová latencia – vysoká latencia, $A = [100, \infty)$*
 - *Monitorovanie straty paketov – nadpolovičná strata paketov, $A = (50, 100]$*

Klasická definícia pravdepodobnosti

- Nech náhodný pokus spĺňa tieto vlastnosti – množina výsledkov je konečná, každá elementárna udalosť je rovnako pravdepodobná a navzájom sa vylučujúca.
- Laplaceova definícia pravdepodobnosti:

$$P(A) = \frac{m}{n} = \frac{|A|}{|\Omega|}$$

- Pravdepodobnosť je pomer priaznivých výsledkov k celkovému počtu rovnako možných výsledkov.

Klasická definícia pravdepodobnosti

- Pravdepodobnosť, že pri hode kockou padne párne číslo

$$P(A) = \frac{3}{6}$$

- Pravdepodobnosť, že pri hode dvoma kockami padne súčet 7

$$P(A) = \frac{6}{36}$$

- Pravdepodobnosť, že v dvoch hodoch mincou padne aspoň raz rub

$$P(A) = \frac{3}{4}$$

Štatistická definícia pravdepodobnosti

- Pravdepodobnosť náhodnej udalosti A odhadujeme na základe pozorovania pri opakovaných náhodných pokusoch.
- Definujeme relatívnu početnosť javu A vzorcom

$$\frac{\text{počet výskytov javu } A}{\text{počet nezávislých pokusov}} = \frac{k_n}{n}$$

- Pravdepodobnosť javu A je hodnota, ku ktorému sa blíži relatívna početnosť javu A , ak pokus opakujeme mnohokrát (limitná hodnota jej relatívnej početnosti)

$$P(A) = \lim_{n \rightarrow \infty} \frac{k_n}{n}$$

Štatistická definícia pravdepodobnosti

- Štatistická definícia je základom pre prácu s reálnymi, rozsiahlymi a neúplnými dátami.
- Strojové učenie: Pravdepodobnosť, že e-mail je spam, sa odhaduje na základe frekvencie určitých slov v miliónoch predošlých.
- Odporúčacie systémy: Pravdepodobnosť, že si kúpite produkt B, ak ste si kúpili A, sa počíta z historických transakcií.
- NLP (Natural Language Processing):
 - *Predikcia slova: Telefón vie navrhnúť ďalšie slovo, pretože spočítal, čo po danej fráze najčastejšie nasleduje v miliónoch textov.*
 - *Analýza sentimentu: Softvér vie rozpoznať, či je recenzia pozitívna alebo negatívna, a to na základe frekvencie slov, ktoré sú historicky spojené s jedným alebo druhým sentimentom.*

Axiomatická definícia pravdepodobnosti

- Klasický prístup zlyháva, ak výberový priestor Ω je nekonečný.
- Pravdepodobnosť $P(A)$ je reálna funkcia, ktorá priradí javu A číslo $P(A)$. Funkcia je definovania pomocou axióm ako objektívna vlastnosť náhodnej udalosti A .
- Definícia nedáva jednoznačný návod na výpočet pravdepodobnosti náhodnej udalosti.
- Axiomatická teória poskytla matematicky presný a konzistentný rámec pre teóriu pravdepodobnosti, prepojila teóriu pravdepodobnosti s teóriou miery a integrálu.
- Andrej Nikolajevič Kolmogorov sformuloval axiómy, ktoré definujú pravdepodobnosť ako *normalizovanú mieru na σ –algebre náhodných udalostí*.

Axiomatická definícia pravdepodobnosti

σ – algebra

- Nech Ω je neprázdna množina. Množinovou σ – algebrou nazveme systém podmnožín S množiny Ω s vlastnosťami:
 - $\emptyset, \Omega \in S$
 - ak $A \in S$ potom aj $A^c \in S$
 - ak $A_1, A_2, \dots, A_i, \dots \in S$ potom aj $\bigcup_i A_i \in S$
- σ – algebra:
 - Zabezpečuje, že s náhodnými udalosťami môžeme pracovať logicky a matematicky korektne
 - Umožňuje konzistentne prirad'ovať pravdepodobnosti, najmä pri nekonečnom počte možností

Axiomatická definícia pravdepodobnosti, miera

- Miera μ je funkcia, ktorá priradzuje „veľkosť“ alebo „objem“ určitým podmnožinám nejakej množiny. Miera je zovšeobecnenie známych pojmov ako dĺžka, plocha alebo objem.
- Nech je daná množina X a nech S je σ – algebra na X . Funkcia $\mu: S \rightarrow [0, \infty]$ sa nazýva miera, ak spĺňa nasledujúce tri podmienky (axiómy miery):
 - *nezápornosť* : Pre každú množinu $A \in S$ platí $\mu(A) \geq 0$
 - *miera prázdnej množiny je nulová*: $\mu(\emptyset) = 0$
 - *σ – aditivita (spočítateľná aditivita)*: Pre každú spočítateľnú postupnosť vzájomne disjunktných množín $A_1, A_2, A_3, \dots, A_i \cap A_j = \emptyset, i \neq j$, platí

$$\mu\left(\bigcup_i A_i\right) = \sum_i \mu(A_i)$$

Axiomatická definícia pravdepodobnosti, axiómy

- Definícia: Nech $\Omega \neq \emptyset$, S je σ -algebra podmnožín množiny Ω . Pravdepodobnostná miera (pravdepodobnosť) je funkcia $P: S \rightarrow [0,1]$ s nasledujúcimi vlastnosťami
 - platí $P(A) \geq 0$, pre $A \in S$ nezápornosť
 - $P(\Omega) = 1$, normovanosť
 - ak $A_n \in S, n = 1, 2, \dots$ a $A_i \cap A_j = \emptyset$ pre $i \neq j$ potom $P(\bigcup_n A_n) = \sum_n P(A_n)$, σ -aditivita
- Trojica (Ω, S, P) sa nazýva pravdepodobnostný priestor.
- Klasická definícia pravdepodobnosti spĺňa tieto axiómy, je však iba špeciálnym prípadom pravdepodobnostnej miery.

Náhodná premenná, úvod

- Výsledky pokusu boli uvádzané slovne, číselne.
- V praxi je vhodnejšie priradiť výsledku pokusu číslo, aby sa výsledky dali analyzovať.
- Toto priradenie (funkcia) sa nazýva náhodná premenná (*n.p., random variable*), označenie $X, Y, Z \dots$
- Definícia: Nech (Ω, S, P) je pravdepodobnostný priestor. Funkcia $X: \Omega \rightarrow R$, pre ktorú platí, že pre každé $x \in R, X^{-1}((-\infty, x]) = \{e \in \Omega, X(e) \leq x\} \in S$ sa nazýva náhodná premenná.
- Podmienka v definícii zaručuje, že náhodná premenná X je merateľná, pre každý výsledok x môžeme vypočítať pravdepodobnosť $P(X \leq x)$.

Náhodná premenná

- Diskrétna náhodná premenná - oborom hodnôt sú izolované body (čísla) na reálnej osi.
- Spojitá náhodná premenná - oborom hodnôt je interval (môže nadobudnúť ľubovoľnú hodnotu z daného intervalu).
- Určte, ktorá z náhodných premenných je diskretná a ktorá spojitá:
 - *počet kliknutí na reklamu*
 - *Čas odozvy servera na požiadavku*
 - *počet zákazníkov čakajúcich na obsluhu*
 - *životnosť súčiastky alebo zariadenia*
 - *chyba merania rozmeru súčiastky*

Charakteristiky náhodnej premennej

- Základnými charakteristikami náhodnej premennej sú
 - *Rozdelenie pravdepodobnosti (Probability Distribution)*
 - *Distribučná funkcia (Distribution Function)*
 - *Momentové charakteristiky (Moments)*

Charakteristiky náhodnej premennej

- Rozdelenie pravdepodobnosti popisuje všetky možné hodnoty, ktoré môže náhodná premenná nadobudnúť a priradzuje im pravdepodobnosti, s akými sa tieto hodnoty vyskytnú.
- Distribučná funkcia (kumulatívna distribučná funkcia, CDF) je kumulatívne rozdelenie pravdepodobnosti. Pre danú hodnotu x udáva pravdepodobnosť, že náhodná premenná X nadobudne hodnotu menšiu alebo rovnú x .

$$F(x) = P(X \leq x)$$

- Momenty sú číselné charakteristiky, ktoré poskytujú informácie o tvare, polohe a disperzii rozdelenia pravdepodobnosti. Rozlišujeme dva hlavné typy momentov: začiatočné (General Moment) momenty a centrálné momenty (Central Moment).
- K – ty začiatočný moment : $E'_k(X) = E(X^k) = \mu'_k$
- Prvý začiatočný moment sa nazýva stredná hodnota (očakávaná hodnota, ťažisko), $E(X) = \mu$.
- K –ty centrálny moment: $E_k(X) = E\left((X - E(X))^k\right) = \mu_k$
- Druhý centrálny moment (disperzia) je charakteristikou variability
$$E_2(X) = D(X) = \sigma^2 = E((X - E(X))^2)$$

Momentové charakteristiky

- Rozdelenie pravdepodobnosti je dané tabuľkou, predpisom

$$p_i = P(X = x_i), \text{ platí } 0 \leq p_i \leq 1, \sum_i p_i = 1$$

- Distribučná funkcia

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} P(X \leq x_i) = \sum_{x_i \leq x} p_i$$

- Momenty stredná hodnota a disperzia

$$E(X) = \sum_i x_i p_i = \mu, D(X) = \sum_i (x_i - \mu)^2 p_i$$

Diskrétna náhodná premenná


Diskrétna náhodná premenná

- Príklad: Hádžeme dvomi kockami, výsledku pokusu priradíme maximum bodov, ktoré padli. Náhodná premenná je daná predpisom

$$X(e_{1i}, e_{2i}) = \max(e_{1i}, e_{2i}) = x_i$$

- Určte tabuľku rozdelenia pravdepodobnosti, nakreslite graf rozdelenia pravdepodobnosti, vypočítajte strednú hodnotu a disperziu.

x_i	1	2	3	4	5	6
p_i	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$



Spojité náhodné premenne

Spojité náhodné premenne nadobúda ľubovoľnú hodnotu v danom intervale, obor hodnôt je interval.

Príklady spojitej náhodnej premennej

- výška človeka
- doba obsluhy
- doba do prvej poruchy prístroja
- čas odozvy servera na požiadavku
- jas pixelu na obrázku

Existujú aj zmiešané náhodné premenne, nimi sa nebude zaoberať.

- Funkcia $f(x)$ sa nazýva hustota pravdepodobnosti spojitej náhodnej premennej X , ak platí:
 - $f(x) \geq 0$
 - $f(x)$ je po častiach spojitá (má konečný počet bodov nespojitosti)
 - $\int_{-\infty}^{\infty} f(x)dx = 1$
- Hustota pravdepodobnosti (Probability Density Function, PDF)
 - Prirad'uje pravdepodobnosť pre interval hodnôt $P(a \leq X \leq b) = P(a < X < b)$
 - Pravdepodobnosť, že spojitá náhodná premenná nadobúda konkrétnu hodnotu x_0 je nulová

Pravdepodobnostná funkcia spojitej náhodnej premennej

- Definícia: Nech (Ω, S, P) je pravdepodobnostný priestor. Funkciu $F: R \rightarrow [0, 1]$ definovanú predpisom $F(t) = P(X \leq t)$ nazveme distribučnou funkciou náhodnej premennej X .
- Distribučná funkcia (Distribution Function, CDF) náhodnej premennej X spĺňa tieto vlastnosti
 - $D(F) = R, H(F) = [0, 1]$
 - $F(x)$ je neklesajúca a sprava spojitá
 - $F(-\infty) = 0, F(\infty) = 1$
 - $P(a \leq X \leq b) = F(b) - F(a)$

Distribučná funkcia spojitej náhodnej premennej