

A thick black L-shaped frame is positioned on the left and bottom edges of the slide, framing the central text.

ŠTATISTICKÁ ANALÝZA DÁT V R

Úvod do dátovej analýzy

- V dnešnej dobe vzniká a spracováva sa veľké množstvo nehmotných informácií a údajov, ktoré sú primárne vo forme elektronických dát. Masívne objemy dát vyžadujú systematickú analýzu a interpretáciu.
- Dáta, ktoré štatisticky analyzujeme, získavame niekoľkými spôsobmi:
 - *Vlastný zber dát (návrh a vykonanie experimentu, vlastný výskum, merania, šetrenia v teréne)*
 - *Dátový súbor poskytnutý klientom, zadávateľom štatistickej analýzy*
 - *Štatistické výkazy (zdravotné dokumentácie, firemné dáta, dáta daňového úradu, štátnej inštitúcie)*
- Zvyčajne nie sme schopní (ochotní, vzhľadom na čas a financie) urobiť šetrenia veľkých rozsahov, preto pracujeme s výberovým súborom.

Jednorozmerný štatistický súbor

Štatistický súbor je súborom štatistických jednotiek, ako sú merania, odpovede z dotazníkov alebo iné zozbierané údaje.

Ak analyzujeme všetky jednotky, ide o úplné šetrenie. Súbor všetkých jednotiek sa nazýva populácia.

Úplné šetrenie je často príliš časovo, finančne alebo technicky náročné. Preto pracujeme s reprezentatívnou vzorkou, na základe ktorej zovšeobecníme výsledky na celú populáciu.

Táto vzorka sa najčastejšie získava pomocou náhodného výberu (random sample).

Analyzujeme jednorozmerné kvantitatívne (číselné) merania spojitej alebo nespojitej povahy.

Viacrozmerňý šťatistický súbor

Merania (kódy meraní) sa zaznamenávajú do tabuľky, pričom každý objekt (prípad, pozorovanie) má priradený jeden riadok.

Riadky definujú počet skúmaných objektov, stĺpce predstavujú merané znaky, vlastnosti, premenné.

Konečným výsledkom je dátová matica vo forme tabuľky, ktorá prehľadne zachytáva všetky získané údaje.

	1.premenná — sledovaný znak	2.premenná — sledovaný znak	
1. objekt	$meranie_{11}$	$meranie_{12}$	...
2. objekt	$meranie_{21}$	$meranie_{22}$	...
.....			...

	Vek:	Počet rokov praxe:	Na akom type oddeleni	1. f
	35-44 rokov	6-15 rokov	KAIM	
	55-64 rokov	35 rokov <	chirurgické disciplíny	
	55-64 rokov	35 rokov <	internistické disciplíny	
	< 34 rokov	< 5 rokov	KAIM	
	45-54 rokov	16-25 rokov	KAIM	
	< 34 rokov	6-15 rokov	KAIM	
	55-64 rokov	35 rokov <	internistické disciplíny	
	55-64 rokov	35 rokov <	chirurgické disciplíny	
	< 34 rokov	6-15 rokov	KAIM	
	< 34 rokov	6-15 rokov	KAIM	
	35-44 rokov	16-25 rokov	KAIM	
	45-54 rokov	26-35 rokov	KAIM	
	< 34 rokov	6-15 rokov	KAIM	
	35-44 rokov	16-25 rokov	KAIM	
	45-54 rokov	16-25 rokov	KAIM	
	45-54 rokov	26-35 rokov	internistické disciplíny	

Žižková		* nie je určený dátum vplyvu počasia															
		* 10 buniek/kontajnerov (prišli zmeny)		3 624,55													
		* predbežne stanovená oblasť															
		36 245,48		12 956,74		9 725,39		13 563,34		SHMÚ		výroba FVE					
		kontajner										3,12 kWp		5,07 kWp		10,14 kWp	
dátum	čas	spotreba (Wh)	L1	L2	L3	teplota	viator	0°		opti 40°		0°		opti 40°		0°	
12.2022	0:00	7 984,08	3 939,66	2 663,91	1 380,51	1,31	0,76	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	1:00	7 966,20	3 910,31	2 705,25	1 350,64	1,00	0,44	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	2:00	8 062,49	3 998,64	2 706,23	1 357,62	0,66	0,39	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	3:00	8 056,66	3 926,13	2 749,91	1 380,62	0,10	0,43	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	4:00	8 066,19	3 895,59	2 833,49	1 337,11	-0,39	0,07	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	5:00	7 991,03	3 809,28	2 816,52	1 365,23	-0,48	0,32	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	6:00	8 473,60	3 752,22	3 164,31	1 557,07	-0,34	0,35	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
12.2022	7:00	10 463,42	4 579,77	4 115,12	1 768,54	0,43	0,63	90,98	405,91	147,84	659,61	295,68	1319,21				
12.2022	8:00	10 004,79	4 320,00	3 298,19	2 386,61	1,41	0,89	366,35	1074,75	595,32	1746,46	1190,64	3492,93				
12.2022	9:00	9 785,35	4 076,48	2 330,37	3 378,51	2,85	0,97	596,67	1424,59	969,59	2314,96	1939,17	4629,92				
12.2022	10:00	9 217,30	3 706,29	2 100,35	3 410,67	3,13	1,42	816,88	2099,88	1327,43	3412,31	2654,85	6824,63				
12.2022	11:00	10 633,35	3 279,65	1 962,84	5 390,86	3,79	1,89	819,38	2080,51	1321,75	3380,83	2643,50	6761,66				
12.2022	12:00	9 506,28	2 786,46	1 955,28	4 764,54	4,30	1,45	501,29	921,68	814,60	1497,73	1629,19	2995,46				
12.2022	13:00	9 651,03	2 837,19	1 892,55	4 921,29	4,84	1,55	157,62	147,70	256,14	240,01	512,27	480,03				
12.2022	14:00	2 454,90	1 417,46	389,96	647,49	3,98	1,05	1,84	0,97	2,99	1,57	5,98	3,14				
12.2022	15:00	6 732,07	3 904,76	1 087,26	1 740,06	3,05	1,06	0,00	0,00	0,00	0,00	0,00	0,00				
12.2022	16:00	7 846,62	4 536,80	1 655,04	1 654,79	2,49	0,75	0,00	0,00	0,00	0,00	0,00	0,00				
12.2022	17:00	6 843,13	3 769,97	1 649,43	1 423,74	1,61	1,04	0,00	0,00	0,00	0,00	0,00	0,00				

Príklady reálnych dátových tabuliek

- Medikačné chyby pri podávaní liekov, dotazník.
- Analýza potenciálu zníženia energetickej náročnosti staveniskovej prevádzky.

Typy premenných

- Každé meranie sa zaznamenáva do samostatnej premennej. Premenné rozdeľujeme na dva základné typy.
- Kvantitatívne premenné
 - *Spojité: Nadobúdajú akúkoľvek hodnotu v danom intervale (napr. dĺžka, výška, hmotnosť, čas).*
 - *Diskrétné: Nadobúdajú len celé hodnoty (napr. počet členov domácnosti, počet objednávok).*
- Kvalitatívne premenné
 - *Popisujú určitú vlastnosť alebo kategóriu.*
 - *Nominálne: Nedá sa určiť ich poradie (napr. národnosť, typ školy).*
 - *Ordinálne: Hodnoty vieme usporiadať, ale nevieme určiť rozdiel medzi nimi (napr. stupeň spokojnosti, vzdelanie).*

Exploračná analýza dát (EDA)

- EDA – Prvotná analýza dát na spoznanie štruktúry datasetu.
- Cieľ – Odhaliť kľúčové vlastnosti datasetu pomocou štatistických charakteristík a vhodných grafov. Identifikovať chybné a odľahlé hodnoty, nahradiť chýbajúce pozorovania vhodnou metodikou.
- Príklad: Výdrž batérie notebooku
 - *Sledovaná premenná: Doba činnosti batérie do vybitia v minútach (závisí od kapacity, výbavy a záťaže) notebook, Analyzujte a vizualizujte dáta.*
272, 182, 274, 349, 240, 265, 204, 264, 255, 243, 245, 301, 260, 282, 223,

Príprava dát, usporiadanie

- Zoradenie hodnôt - Vzostupné usporiadanie hodnôt

$$\min = x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} = \max$$

- Tabuľky početností - Súhrn absolútnych a relatívnych početností pre jednotlivé hodnoty alebo triedy.
- Konštrukcia triednych intervalov
 - Počet tried: (Sturgesovo pravidlo) $k = 1 + 3.3\log(n)$, iné pravidlo, subjektívny výber
 - Šírka intervalu: $k = \frac{x_{\max} - x_{\min}}{k}$ (okrem krajných tried)
 - Reprezentant triedy: Stred (zvyčajne priemerná hodnota hraníc intervalu).

Tabuľka početností a triednych početností

Tabuľka početností prvkov

- Prvý stĺpec je meranie, druhý stĺpec početnosť alebo relatívna merania (výstup z R)

Tabuľka triednych početností

- Hranice tried a početnosti v triedach, reprezentant triedy je stred intervalu

Čas	do 150	151–200	200–250	250–300	300–3050	nad 350
Početnosť	0	2	13	13	2	0

Čas	Početnosť
163	1
182	1
204	1
207	1
211	1
221	1
223	1
230	1
233	1
240	1
243	1
244	1
245	1
248	2
251	1
252	1
253	1
254	1
255	1
259	1
260	1
264	1
265	1
272	1
274	1
278	1
282	1
301	1
349	1

Čas	Relatívna_p
163	0.0333333
182	0.0333333
204	0.0333333
207	0.0333333
211	0.0333333
221	0.0333333
223	0.0333333
230	0.0333333
233	0.0333333
240	0.0333333
243	0.0333333
244	0.0333333
245	0.0333333
248	0.0666667
251	0.0333333
252	0.0333333
253	0.0333333
254	0.0333333
255	0.0333333
259	0.0333333
260	0.0333333
264	0.0333333
265	0.0333333
272	0.0333333
274	0.0333333
278	0.0333333
282	0.0333333
301	0.0333333
349	0.0333333

Charakteristiky polohy, priemer

- Štatistické miery na určenie polohy alebo centrálnej tendencie súboru dát. Poskytujú jednu hodnotu, ktorá reprezentuje celú skupinu.
- Aritmetický priemer — (odhad strednej hodnoty, výberová stredná hodnota).
- Aritmetický priemer je citlivý na extrémne (vybočujúce) hodnoty, charakteristika vhodná len pre homogénne súbory dát

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Charakteristiky polohy, priemer

■ Harmonický priemer

- *Harmonický priemer slúži na vyhodnotenie pomerových veličín alebo prevrátených hodnôt*
— *typicky pri výpočte priemernej rýchlosti, produktivity práce či finančných sadzieb,*

$$\bar{x}_H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

■ Geometrický priemer

- *Geometrický priemer počítame pre dáta, ktoré sa menia násobením a neprebíha medzi nimi prosté sčítanie. Je určený pre kladné hodnoty vyjadrujúce relatívne zmeny, napríklad miery rastu, výnosy investícií alebo indexy inflácie.*

$$\bar{x}_G = \sqrt[n]{x_1 x_2 \dots x_n}$$

Charakteristiky polohy

■ Harmonický priemer, príklady použitia.

- *Troja robotníci vykonajú rovnakú operáciu za 3, 4 a 6 minút. Ako dlho trvá v priemere táto operácia? (4 minúty)*

$$\bar{x} = \frac{3}{\frac{1}{3} + \frac{1}{4} + \frac{1}{6}} = 4$$

- *Auto prejde polovicu cesty rýchlosťou 20km/h a druhú polovicu cesty rýchlosťou 80km/h. Aká je priemerná rýchlosť auta? (32km/h)*

$$\bar{x} = \frac{2}{\frac{1}{20} + \frac{1}{80}} = 32$$

Charakteristiky polohy, geometrický priemer

- Výška čistého ročného príjmu zamestnanca firmy ABC bola postupne za tri roky 10 000 €, 12 000 € a 12500 €. Určte koeficienty rastu a priemerný koeficient rastu.

príjem	koeficient rastu	relatívny prírastok
10 000 €	--	--
12 000 €	$\frac{12000}{10000} = 1,2$	20%
12 500 €	$\frac{12500}{12000} = 1,042$	4,2%

- $\bar{x}_G = \sqrt{1,2 \cdot 1,042} = 1,12$. Priemerný koeficient rastu je 1,12, príjem rástol priemerne ročne o 12%.

Robustné miery polohy

- Robustnosť v štatistike znamená, že daná miera je odolná voči extrémom alebo odľahlým hodnotám (*outliers*).
- Na rozdiel od aritmetického priemeru, ktorý je na tieto hodnoty veľmi citlivý, medián a modus zostávajú nezmenené, aj keď sa v súbore objavia extrémne vysoké alebo nízke hodnoty.
- Modus Mo – najpočetnejšia hodnota súboru, Akákoľvek extrémna hodnota, ktorá sa vyskytuje len raz, nemá na modus žiadny vplyv.
- Medián Me – prostredná hodnota v usporiadanom poradí, tiež 0,5 *kvantil* alebo druhý kvartil Q_2 .

Kvartily a kvantily

- Kvantil k_p rozdeľuje zotriedené dáta na dve časti v pomere p a $(1 - p)$.
- Aspoň $p \cdot 100 \%$ hodnôt je menších alebo rovných k_p a zvyšok $(1 - p) \cdot 100 \%$ je väčších alebo rovných k_p .
- Výpočet
 - Dáta zotriedime od najmenšieho po najväčšie ($x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$).
 - Vypočítame index $j = \lfloor n \cdot p \rfloor$ (celá časť zo súčinu).
 - Určíme kvantil k_p :
 - Ak je $n \cdot p$ celé číslo: $k_p = \frac{x_{(j)} + x_{(j+1)}}{2}$ (priemer dvoch susedných hodnôt)
 - Ak $n \cdot p$ nie je celé: $k_p = x_{(j+1)}$ (hodnota na nasledujúcej pozícii)

Charakteristiky polohy, príklad

- Zrátajte charakteristiky polohy pre dáta príkladu 1. Určíme poradia pre $k_{0,25} = Q_1$, $k_{0,5} = Q_2 = Me$ a $k_{0,75} = Q_3$, $[30 \cdot 0,25] = [7,5] = 7$, $[30 \cdot 0,5] = [15] = 15$, $[30 \cdot 0,75] = [22,5] = 22$, $Q_1 = x_{(8)}$, $Q_3 = x_{(23)}$, $Q_2 = Me = \frac{x_{(15)} + x_{(16)}}{2}$

priemer	$\bar{x} = 247,033$
harmonický a geometrický priemer	nemá zmysel rátať
medián	$Me = 249,5$
modus	$Mo = 248$
prvý a tretí kvartil	$Q_1 = 230, Q_3 = 264$

Charakteristiky rozptylu

- Rozptyl, alebo variabilita, je štatistická miera, ktorá opisuje, ako sú dátové body v súbore dát rozmiestnené.
- Dopĺňa miery centrálnej tendencie (ako je priemer), ktoré nám hovoria, kde je stred dát, zatiaľ čo rozptyl popisuje ich variabilitu.
- Nízky rozptyl naznačuje, že dáta sú konzistentné a spoľahlivé. Ak napríklad opakované merania majú nízky rozptyl, znamená to, že proces merania je presný (spoľahlivosť).
- Vo financiách sa rozptyl používa na meranie volatility a rizika. Vyšší rozptyl znamená vyššie riziko (hodnotenie rizika).

Charakteristiky rozptylu

- Variačné rozpätie (Range): Najjednoduchšia miera rozptylu, vypočítaná ako rozdiel medzi maximálnou a minimálnou hodnotou v súbore dát.

$$x_{max} - x_{min}$$

- Medzikvartilové rozpätie (IQR): Rozdiel medzi tretím a prvým kvartilom, predstavujúci rozptyl stredných 50 % dát. Je menej ovplyvnené odľahlými hodnotami ako rozpätie.

$$IQR = Q_3 - Q_1$$

- Kvartilová odchýlka

$$\frac{IQR}{2}$$

- Test vybočujúcich (*outlier*, $k = 1,5$) a extrémálnych hodnôt (*far out*, $k = 3$)

$$x_i \notin (Q_1 - k \cdot (Q_3 - Q_1), Q_3 + k \cdot (Q_3 - Q_1))$$

Charakteristiky rozptylu

- Rozptyl (Variance), základná miera, odchýlky od priemeru sa umocňujú, čo môže sťažiť jej interpretáciu.

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- Štandardná odchýlka (Standard Deviation): Druhá odmocnina rozptylu, najpoužívannejšia miera rozptylu, je v rovnakých jednotkách ako pôvodné dáta.
- Priemerná absolútna odchýlka (MAD), menej citlivá na extrémne hodnoty

$$\bar{d} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Charakteristiky rozptylu

- Variačný koeficient V_x , miera relatívnej variability, bezrozmerné číslo a umožňuje porovnať mieru variability dvoch (viac) súborov s odlišnou úrovňou hodnôt. Zvyčajne udáva v percentách



$$V_x = \frac{s_x}{\bar{x}}$$

- Porovnanie variability cien nehnuteľností v Bratislave ($\bar{x} = 300\,000$ €, $s_x = 45\,000$ €) a v menšom meste ($\bar{x} = 100\,000$ €, $s_x = 25\,000$ €).

$$V_x(B) = \frac{45000}{300000} \cdot 100\% = 15\%, \quad V_x(M) = \frac{25000}{100000} \cdot 100\% = 25\%$$

- Relatívna variabilita cien je oveľa väčšia v menšom meste. Konzistentné dáta majú variačný koeficient pod 10%, hodnoty nad 25% - dáta sú variabilné a nehomogénne.

Iné charakteristiky



- Nech m_k je bodový odhad k-teho centrálného momentu $m_k = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^k$.
- Výberová šikmosť (skewness)
 - $\hat{\gamma}_3 = a_3 = \frac{m_3}{s_x^3}$. Ak $a_3 = 0$, ide o symetrický súbor, $a_3 > 0$, kladne zošikmený súbor ($Mo < Me < \bar{x}$), $a_3 < 0$, záporne zošikmený súbor ($Mo > Me > \bar{x}$).
- Výberová špicatosť (kurtosis)
 - $\hat{\gamma}_4 = a_4 = \frac{m_4}{s_x^4}$, $a_4 = 3$, špicatosť normálne rozdeleného súboru, $a_4 > 3$, špicatý (leptokurtic) súbor, $a_4 < 3$, plochý (platykurtic), v štatistických výpočtoch sa zvykne centrovať $a_4 - 3$.


Charakteristiky rozptylu

■ Charakteristiky rozptylu

variačné rozpätie	$349 - 163 = 186$
priemerná absolútna odchýlka	24,36
výberový rozptyl s_x^2	1235,137
výberová smerodajná odchýlka	35,144
kvartilové rozpätie IQR	34
kvartilová odchýlka	17
šikmosť	0,195
špicatosť	4,59






Grafy štatistickej analýzy a R

- Program R ponúka viacero knižníc na tvorbu vizualizácií.
- Okrem základných príkazov (knižnica base) je k dispozícii aj balík lattice na vytváranie viacpanelových grafov.
- Vhodným nástrojom je knižnica ggplot2, ktorá je postavená na koncepcii „Gramatiky grafiky“ (grammar of graphics). Tento premyslený systém umožňuje vytvárať profesionálne grafy z jednotlivých logických vrstiev.
- Hadleyho Wickham: <https://ggplot2-book.org/>.




Grafy štatistickej analýzy

- Histogram
- Krabicové (box-whisker chart) grafy
- Husľový graf (violin chart, zobrazuje nielen štatistické zhrnutia ako medián a kvartily, ale hustotu dát)
- Jitter plot
- Empirická distribučná funkcia



Grafy štatistickej analýzy

- Jitter plot (alebo aj jittered plot, jittered strip plot) je graf na vizualizáciu hustoty dát.
- Rieši problém prekrývania bodov (*overplotting*), kde sa body s rovnakou hodnotou prekrývajú a nie je vidieť ich skutočný počet.
- Pridáva malý náhodný „šum“ k pozícii každého bodu. Body, ktoré by inak ležali na sebe, sa vďaka tomu rozptýlia.



Vhodné knihovny R

- Prvotná výpočtová analýza – psych, Hmisc, FSA, pastecs, moments, mosaic, lmom, lmomco, Lmoments.
- Grafická analýza – ggplot2, plotly, lattice (doplňky -RColorBrewer, vioplot, ROCR).