

TEÓRIA ODHADU

Intervaly spoľahlivosti pre parametre normálneho
rozdelenia, bootstrapove intervaly spoľahlivosti pre daný
parameter

Teória odhadu

- Štatistická oblasť: Metódy na odhadovanie neznámych parametrov populácie.
- Problém: Práca s obmedzenou a zašumenou vzorkou dát (testovacie spustenia, trénovacie sady).
- Cieľ: Určiť skutočnú hodnotu parametra (napr. priemer RAM, váha modelu) a kvantifikovať neistotu.
- Dva typy odhadov
 - *Bodový odhad parametra“ priemer RAM z 50 testovacích spustení je 8,2GB*
 - *Intervalový odhad parametra: S istou, dopredu známou spoľahlivosťou sa priemerná spotreba nachádza medzi 7,5 – 8,9GB*

Bodový odhad

- Náhodný výber $(X_1, X_2, \dots, X_n)$: Súbor n nezávislých a rovnako rozdelených náhodných premenných (*I.I.D.* – Independent and Identically Distributed).
- Význam premenných: Reprezentujú dáta z opakovaného merania za identických podmienok.
- Realizácia náhodného výberu: Jedna konkrétna množina nameraných hodnôt $(x_1, x_2, \dots, x_n)$ z n –krát opakovaného merania.
- Štatistika T_n : Akákoľvek funkcia náhodného výberu $T_n(X_1, X_2, \dots, X_n)$, ktorá je sama o sebe náhodnou premennou.

Vlastnosti bodových odhadov

- Nevychýlenosť (Unbiasedness): Odhad je nevychýlený, ak sa jeho stredná hodnota (očakávaná hodnota) rovná skutočnej hodnote odhadovaného parametra populácie.

$$E(T_n) = \theta$$

- V praxi to znamená, že odhad pri opakovanom výbere nepreceňuje ani nepodceňuje skutočný parameter. V dlhodobom horizonte je v priemere "správny".
- Odhad je konzistentný, ak sa s rastúcim rozsahom výberu n stáva štatisticky čoraz bližším skutočnej hodnote parametra (konverguje k nej v pravdepodobnosti).
- S väčším množstvom zozbieraných údajov (väčšou vzorkou) je náš odhad presnejší a spoľahlivejší.

Vlastnosti bodových odhadov

- Nevychýlený odhad je výdatný (efektívny), ak má zo všetkých možných nevychýlených odhadov daného parametra najmenší rozptyl.
- MVUE (*Minimum Variance Unbiased Estimator*) - nevychýlený odhad s minimálnym rozptylom (niekedy sa označuje aj ako *najlepší nevychýlený odhad*).
- Odhad je dostatočný (sufficiency), ak využíva všetky relevantné informácie obsiahnuté vo vzorke, ktoré sú potrebné na odhadnutie daného parametra.

Metódy odhadov

- Momentová metóda (Method of Moments – MOM): Odhad parametrov touto metódou spočíva v porovnaní teoretických momentov náhodnej premennej (vyjadrených pomocou neznámych parametrov) s empirickými momentmi získanými priamo z nameraných dát. Zostavíme a vyriešime sústavu k rovníc, v ktorých sa prvých k empirických momentov rovná prvým k teoretickým momentom.
- Metóda maximálnej vierohodnosti (Maximum Likelihood Estimation – MLE): Metóda je založená na nájdení takého odhadu $\hat{\theta}$ pre neznámy parameter θ , pri ktorom vierohodnostná funkcia (resp. jej logaritmus) nadobúda maximálnu hodnotu. Hľadáme takú hodnotu parametra, pre ktorú by boli dáta, ktoré sme reálne namerali, štatisticky „najpravdepodobnejšie“ (najviac vierohodné).

Metódy odhadov

- Bootstrapová metóda (Bootstrap Method): Resamplingová metóda (výber s vracaním). Ak nepoznáme teoretické rozdelenie dát alebo ak ide o odhad robustných parametrov, analytické odvodenie presnosti a rozdelenia odhadu je často nemožné. Pomocou počítačových simulácií a metód resamplingu vieme opakovaným generovaním výberov numericky aproximovať hodnotu odhadu, jeho rozptyl a príslušný interval spoľahlivosti. Výpočtový výkon nahrádza chýbajúcu teoretickú štruktúru.
- Metóda najmenších štvorcov (LSE): Základná optimalizačná metóda v regresnej analýze. Hľadá také parametre modelu, ktoré minimalizujú súčet štvorcov rezíduí (odchýlok medzi reálnymi a modelovými hodnotami).

Príklad

- Roztrhnutie vlákna na tkáčskom stave sa riadi Poissonovým rozdelením s parametrom λ , ($E(X) = D(X) = \lambda$, $f(x, \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$). Počas n dní sme namerali n počtov roztrhnutí vlákna $x_1, \dots, x_n$. Momentovou metódou a metódou maximálnej virohodnosti nájdite odhad parametra λ .
- Momentová metóda: Prvý teoretický moment je stredná hodnota $E(X) = \lambda$, prvý empirický moment je aritmetický priemer (odhad strednej hodnoty)

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Metóda maximálnej virohodnosti: maximalizujeme virohodnostnú funkciu

$$L(x_1, \dots, x_n, \lambda) = f(x_1, \dots, x_n, \lambda) = f(x_1, \lambda) f(x_2, \lambda) \dots f(x_n, \lambda) = \prod_{i=1}^n f(x_i, \lambda)$$

Príklad

$$\begin{aligned}\ln L(x_1, \dots, x_n, \lambda) &= \ln \prod_{i=1}^n f(x_i, \lambda) = \\ &= \ln \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \sum_{i=1}^n x_i \ln \lambda - n\lambda - \sum_{i=1}^n \ln(x_i!)\end{aligned}$$

$$\frac{\partial L}{\partial \lambda} = \frac{1}{\lambda} \sum_{i=1}^n x_i - n = 0$$

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i$$

Bodové odhady niektorých známych rozdelení

- Poissonovo rozdelenie $Po(\lambda)$

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i, E(\hat{\lambda}) = \lambda, D(\hat{\lambda}) = \frac{\lambda}{n}$$


- Normálne rozdelenie $N(\mu, \sigma^2)$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, E(\hat{\mu}) = \mu, D(\hat{\mu}) = \frac{\sigma^2}{n}$$

$$\widehat{\sigma^2} = s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Bodový a intervalový odhad

- Bodový odhad (jediné číslo) má len malý význam, pretože nekvantifikuje neistotu ani chybu odhadu (hoci môže byť nevychýlený či efektívny).
- Intervalový odhad (*IS/CI*): Rieši tento problém – umožňuje chybu vopred určiť a kontrolovať.
- Definícia: Interval spoľahlivosti je interval, v ktorom sa skutočná hodnota neznámeho parametra θ nachádza s vopred danou pravdepodobnosťou.



Intervalový odhad

- Intervalový odhad (konfidenčný interval, CI): Vymedzený dolnou (L) a hornou (U) hranicou: $P(L < \theta < U) = 1 - \alpha$.
- Hladina spoľahlivosti ($1 - \alpha$): Pravdepodobnosť, že konštruovaný interval skutočne obsahuje neznámy parameter θ (zvyčajne 0,9; 0,95; 0,99). Prednastavená hodnota je 0,95 ($\alpha = 0,05$).
- Interpretácia: Pri opakovanom vzorkovaní by približne 95 zo 100 intervalov prekryvalo skutočnú hodnotu parametra.
- Výhoda: Kvantifikuje neistotu, namiesto nepresného bodového odhadu poskytuje intervalové rozmedzie pre lepšie rozhodovanie.

Typy intervalových odhadov

- Obojstranný interval (two tailed): Najčastejší *IS*, ohraničuje parameter zhora aj zdola, $P(L < \theta < U) = 1 - \alpha$.
- Jednostranný pravostranný (lower tailed) interval: (L, ∞) .
- Jednostranný ľavostranný (upper tailed) interval: $(-\infty, U)$.
- V teórii názov označuje umiestnenie intervalu, zatiaľ čo v programovacej praxi (R/Python) sa môže viazať na vynechaný chvost rozdelenia – (vždy overiť, help).
- Uvedieme *IS* pre parametre normálneho rozdelenia, platí predpoklad, že dáta pochádzajú z normálneho rozdelenia.

IS pre strednú hodnotu μ pri známom rozptyle σ^2

- Rozdelenie bodového odhadu: Pre výberový priemer $\bar{x}$ platí (podľa limitných viet):


$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

- Standardizácia (Z-skóre): Prechod na štandardizované normálne rozdelenie:

$$\frac{\bar{x} - \mu}{\sigma} \sqrt{n} \sim N(0,1)$$

- Pravdepodobnostné ohraničenie $(1 - \alpha)$: Vymedzenie dolnej a hornej hranice intervalu (kvantily normálneho rozdelenia):

$$P\left(u\left(\frac{\alpha}{2}\right) < \frac{\bar{x} - \mu}{\sigma} \sqrt{n} < u\left(1 - \frac{\alpha}{2}\right)\right) = 1 - \alpha$$



IS PRE
PARAMETRE
NORMÁLNEHO
ROZDELENIA

IS pre parametre normálneho rozdelenia

- $100(1 - \alpha)\%$ obojstranný interval spoľahlivosti pre strednú hodnotu μ ak σ je známe

$$\left(\bar{x} - \frac{u\left(1 - \frac{\alpha}{2}\right)\sigma}{\sqrt{n}}, \bar{x} + \frac{u\left(1 - \frac{\alpha}{2}\right)\sigma}{\sqrt{n}} \right)$$

- $100(1 - \alpha)\%$ jednostranné intervaly spoľahlivosti pre strednú hodnotu μ ak σ je známe

$$\left(\bar{x} - \frac{u(1 - \alpha)\sigma}{\sqrt{n}}, \infty \right)$$
$$\left(-\infty, \bar{x} + \frac{u(1 - \alpha)\sigma}{\sqrt{n}} \right)$$

IS pre strednú hodnotu μ pri neznámom rozptyle σ^2

- Náhrada neznámeho rozptylu (smerodajnej odchýlky) jeho odhadom:

$$s_x = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

- Studentovo t -rozdelenie: Štatistika T má symetrické Studentovo rozdelenie s $(n - 1)$ stupňami voľnosti:

$$T = \frac{\bar{x} - \mu}{s_x} \sqrt{n} \sim t_{n-1}$$

- Pravdepodobnostné ohraničenie $(1 - \alpha)$: Vymedzenie dolnej a hornej hranice intervalu (kvantily t -rozdelenia):

$$P\left(t_{n-1}\left(\frac{\alpha}{2}\right) < \frac{\bar{x} - \mu}{s_x} \sqrt{n} < t_{n-1}\left(1 - \frac{\alpha}{2}\right)\right) = 1 - \alpha$$

IS pre strednú hodnotu μ pri neznámom rozptyle σ^2

- 100(1 - α)% obojstranný interval spoľahlivosti pre strednú hodnotu μ ak σ nie je známe

$$\left(\bar{x} - \frac{t_{n-1} \left(1 - \frac{\alpha}{2}\right) s_x}{\sqrt{n}}, \bar{x} + \frac{t_{n-1} \left(1 - \frac{\alpha}{2}\right) s_x}{\sqrt{n}} \right)$$

- 100(1 - α)% jednostranné intervaly spoľahlivosti pre strednú hodnotu μ ak σ nie je známe

$$\begin{aligned} & \left(\bar{x} - \frac{t_{n-1}(1 - \alpha)s_x}{\sqrt{n}}, \infty \right) \\ & \left(-\infty, \bar{x} + \frac{t_{n-1}(1 - \alpha)s_x}{\sqrt{n}} \right) \end{aligned}$$


IS pre disperziu normálneho rozdelenia

- Nevychýlený bodový odhad disperzie je v tvare $s_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}$.
- Štatistika $\frac{(n-1)s_x^2}{\sigma^2}$ má χ^2 rozdelenie s $(n-1)$ stupňami voľnosti, rozdelenie je nesymetrické.
- $100(1 - \alpha)\%$ obojstranný interval spoľahlivosti pre disperziu σ^2

$$\left(\frac{(n-1)s_x^2}{\chi_{n-1}^2 \left(1 - \frac{\alpha}{2}\right)}, \frac{(n-1)s_x^2}{\chi_{n-1}^2 \left(\frac{\alpha}{2}\right)} \right)$$

- $100(1 - \alpha)\%$ jednostranné intervaly spoľahlivosti pre disperziu σ^2

$$\left(0, \frac{(n-1)s_x^2}{\chi_{n-1}^2(\alpha)} \right), \left(\frac{(n-1)s_x^2}{\chi_{n-1}^2(1-\alpha)}, \infty \right)$$



Príklad

- K dispozícii máme údaje o dĺžke času (v sekundách), ktorý strávia používatelia na konkrétnej webovej stránke, vzorka obsahuje 20 meraní.
- Zostrojte 95% obojstranný a jednostranné IS pre strednú hodnotu μ , ak $\sigma = 3,8$.
- Zostrojte 95% obojstranný a jednostranné IS pre strednú hodnotu μ , ak σ nepoznáme.
- Zostrojte 95% obojstranný a jednostranné IS pre strednú hodnotu a pre disperziu.
 $X = \{48, 55, 51, 62, 53, 58, 60, 50, 49, 57, 52, 61, 54, 56, 59, 53, 50, 58, 55, 53\}$

$$\bar{X} = 54,7; \sigma = 3,8; \alpha = 0,05; u(0,975) = 1,96; u(0,95) = 1,64$$

IS pre strednú hodnotu μ pri známom rozptyle σ^2

- 95% obojstranný IS pre strednú hodnotu a známe σ :

$$\left(54,7 - \frac{1,96 \cdot 3,8}{\sqrt{20}}; 54,7 + \frac{1,96 \cdot 3,8}{\sqrt{20}} \right) = (53,03; 56,36)$$

- 95% jednostranné IS pre strednú hodnotu a známe σ

$$\left(54,7 - \frac{1,64 \cdot 3,8}{\sqrt{20}}, \infty \right) = (53,3; \infty)$$

$$\left(-\infty; 54,7 + \frac{1,64 \cdot 3,8}{\sqrt{20}} \right) = (-\infty; 56,09)$$

IS pre strednú hodnotu μ pri neznámom rozptyle σ^2

- 95% obojstranný IS pre strednú hodnotu, ak σ nepoznáme, $s_x = 4,1$; $t_{19}(0,975) = 2,09$

$$\left(54,7 - \frac{2,09 \cdot 4,1}{\sqrt{20}}; 54,7 + \frac{2,09 \cdot 4,1}{\sqrt{20}} \right) = (52,77; 56,62)$$

- 95% jednostranný IS pre strednú hodnotu, ak σ nepoznáme, $t_{19}(0,95) = 1,72$

$$\left(54,7 - \frac{1,72 \cdot 4,1}{\sqrt{20}}; \infty \right) = (53,11; \infty)$$

$$\left(-\infty; 54,7 + \frac{1,72 \cdot 4,1}{\sqrt{20}} \right) = (-\infty; 56,28)$$

IS pre disperziu

- 95% obojstranný IS pre σ^2 , $s_x = 4,1$; $\chi_{19}^2(0,025) = 8,9$; $\chi_{19}^2(0,975) = 32,85$

$$\left(\frac{19 \cdot 4,1^2}{32,85}; \frac{19 \cdot 4,1^2}{8,9} \right) = (9,74; 35,95)$$

- 95% jednostranný IS pre σ^2 , $\chi_{19}^2(0,95) = 30,14$; $\chi_{19}^2(0,05) = 10,11$

$$\left(\frac{19 \cdot 4,1^2}{30,14}; \infty \right) = (10,62; \infty)$$

$$\left(0; \frac{19 \cdot 4,1^2}{10,11} \right) = (0; 31,64)$$

Bootstrap

- Bootstrap neposkytuje nový typ bodového odhadu, ale slúži ako technika na overenie a kvantifikáciu presnosti už existujúceho odhadu.
- Patrí k metódam prevzorkovania (resampling methods), nevyžaduje žiadne predpoklady pre rozdelenie dát.
- Metódu možno použiť aj pre zložité štatistiky, kde chýbajú analytické vzorce pre rozptyl (napr. medián, koeficienty korelácie, komplikované koeficienty regresie).
- Základná myšlienka je, že naša vzorka (X) je najlepším dostupným modelom pre celú populáciu. Namiesto toho, aby sme opakovane brali vzorky z neznámej populácie (čo nevieme urobiť), opakovane berieme vzorky z nášho pôvodného výberu s opakovaním.

Bootstrap(Resampling)

- Empirický základ: Definujeme empirické rozdelenie F_n výberu $X = \{x_1, \dots, x_n\}$ a vypočítame bodový odhad hľadaného parametra $\hat{\theta}$.
- Resampling s vracaním: generujeme R bootstrapových vzoriek $B_1, \dots, B_R$ rozsahu n
- Aproximácia vzorkovacieho rozdelenia: Pre každý výber spočítame odhad $\hat{\theta}_r, r = 1, 2, \dots, R$. Množina odhadov má empirickú bootstrapovú distribúciu.
- Spočítame priemer $\bar{\theta}^* = \frac{1}{R} \sum_{r=1}^R \hat{\theta}_r$ a bootstrapovú štandardnú chybu (bootstrap standard error) $s_b = SE_{boot}$, ktorá je smerodajnou odchýlkou bootstrap distribúcie

$$s_b = \sqrt{\frac{1}{R-1} \sum_{r=1}^R (\hat{\theta}_r - \bar{\theta}^*)^2}.$$

Bootstrapove odhady a intervaly spoľahlivosti

- Percentilový interval spoľahlivosti: ak bootstrapova distribúcia je približne normálna a bias je malý, $(1 - \alpha)\%$ interval spoľahlivosti je v tvare

$$\left(\text{percentil} \left(\frac{\alpha}{2} \right), \text{percentil} \left(1 - \frac{\alpha}{2} \right) \right)$$

- T interval so štandardnou bootstrapovou chybou (bootstrap SE)

$$\left(\hat{\theta} - t_{n-1} \left(1 - \frac{\alpha}{2} \right) s_b, \hat{\theta} + t_{n-1} \left(1 - \frac{\alpha}{2} \right) s_b \right)$$

- Reverzný bootstrapový percentilový interval (basic bootstrap CI), q sú kvantily bootstrapového rozdelenia pre príslušný parameter

$$\left(2\hat{\theta} - q \left(1 - \frac{\alpha}{2} \right), 2\hat{\theta} - q \left(\frac{\alpha}{2} \right) \right)$$

- Bca intervaly spoľahlivosti (bias-Corrected and accelerated (BCa)) – intervaly korigované vzhľadom na vychýlenie odhadu a šikmosť bootstrap distribúcie.
- Vhodná knižnica *mosaic* (iné, komplikovanejšie na použitie: *boot*, *resample*)

Bootstrapové odhady a intervaly spoľahlivosti

- Príklad: $data = \{2, 2, 3, 4, 5, 11, 3, 12, 15, 21, 17, 14, 12, 13, 4, 4\}$, dáta nie sú normálne rozdelené, $\bar{x} = 8,875$
- Bootstrapová vzorka 1: $boot1 = \{4, 2, 12, 5, 15, 12, 14, 5, 21, 21, 5, 17, 5, 2, 17, 17\}$, $\bar{x} = 10.875$

