ŠTATISTICKÉ TESTY

Testy hypotéz pre parametre normálneho rozdelenia

Testy štatistických hypotéz

- Inferenčná štatistika: Odhadovanie vlastností celej populácie (základného súboru) na základe vzorky dát.
- Testovanie hypotéz: Hlavná metóda inferenčnej štatistiky slúžiaca na prijímanie rozhodnutí o vlastnostiach populácie pri obmedzenom množstve dát.
- Rozhodovacie kritérium: Rozhodnutie o prijatí alebo zamietnutí teoretického predpokladu odvodené od miery zhody a sily empirických dôkazov.

Testy štatistických hypotéz

- Štatistická hypotéza: tvrdenie o populácii, ktoré overujeme štatistickými metódami
- Typy hypotéz
  - *Vlastnosti rozdelenia: testy normality, homogenita, náhodnosť.*
  - *Parametre rozdelenia: stredné hodnoty, rozptyly, parametre regresnej analýzy*
  - *Porovnanie súborov: parametre, vlastnosti dvoch (viacerých) súborov*
  - *Vzťahy medzi premennými: závislosti, korelácie*

Formulácia nulovej a alternatívnej hypotézy

- Nulová hypotéza H_0: Tvrdenie, ktorého pravdivosť overujeme testom. Predstavuje *status quo* (pôvodný stav) alebo stav bez akéhokoľvek rozdielu či efektu. Automaticky sa považuje za platnú, kým sa nepreukáže opak.
  - *Príklad: Medzi počtom vstupných dát a časom výpočtu neexistuje lineárna závislosť (korelácia).*

$$H_0: \rho = 0$$

- Alternatívna hypotéza H_1: Tvrdenie, ktoré chceme meraním reálne dokázať. Dôkazne bremeno leží na H_1, musíme priniesť dostatočne silný štatistický dôkaz na to, aby sme mali opodstatnenie zamietnuť H_0 a prijať H_1.
  - *Príklad: Medzi počtom vstupných dát a časom výpočtu existuje pozitívna lineárna závislosť.*

$$H_1: \rho > 0$$

Testovacia štatistika a kritický obor testu

- Testovacia štatistika T_n: Slúži na overenie pravdivosti hypotézy. Počíta sa z náhodnej vzorky $x_1, \ldots, x_n$, nadobúda hodnoty v množine $W = W_\alpha \cup W_\alpha^C$.
- Parameter α predstavuje hladinu významnosti (chyba prvého druhu, Significance Level) testu.
- W_α : Kritický obor testu, ak hodnota $T_n \in W_\alpha$, hypotézu H_0 zamietame, prijímame alternatívu.
- $\mathrm{W}_\alpha^{\mathrm{C}}$: Ak hodnota $T_n \in W_\alpha^C$, hypotézu H_0 nezamietame.

Chyby pri testovaní hypotéz a sila testu

- Chyba 1. druhu (α) — Zamietame nulovú hypotézu H_0, hoci v skutočnosti platí.

$$P(T_n \in W_\alpha \mid H_0 \text{ platí}) = \alpha$$

- Chyba 2. druhu (β) —Nezamietame nulovú hypotézu H_0, hoci neplatí (platí alternatíva H_1).

$$P(T_n \in W_\alpha^c \mid H_1 \text{ platí}) = \beta$$

- Sila testu (Power of the Test) — Pravdepodobnosť správneho zamietnutia H_0, tiež citlivosť/detekčná schopnosť.

$$1 - \beta = P(T_n \in W_\alpha \mid H_1 \text{ platí})$$

Chyby pri testovaní hypotéz

Skutočnosť /Výsledok testu		Skutočnosť	
		H_0 platí	H_0 neplatí
Výsledok testu	nezamietam H_0	správne rozhodnutie pravdepodobnosť $1-\alpha$	chyba 2. druhu pravdepodobnosť β
	zamietam H_0	chyba 1. druhu pravdepodobnosť α	správne rozhodnutie pravdepodobnosť $1-\beta$ sila testu

- Pri fixnom rozsahu výberu platí: Minimalizáciou jednej chyby vždy narastá chyba druhá.
- Kompromis: fixujeme chybu 1. druhu (hladinu významnosti α), minimalizujeme chybu 2. druhu (β) výberom vhodnej testovacej štatistiky.

Rozdelenie testov podľa alternatívnej hypotézy

- Obojstranný test ($H_1: \theta \neq \theta_0$)
  - *Význam: Hľadáme akúkoľvek zmenu (nahor aj nadol).*
  - *Príklad: Líši sa presnosť nového senzora od starého? (nezáleží či je lepši alebo horší).*
- Jednostranný test ($H_1: \theta > \theta_0$ alebo $\theta < \theta_0$)
  - *Význam: Hľadáme zmenu len v jednom konkrétnom smere.*
  - *Príklad: Je nový procesor rýchlejší ako starý?*

Rozdelenie testov podľa závislosti vzoriek

- Závislé (párové) testy
  - *Význam: Testujeme tú istú vzorku v dvoch rôznych stavoch (napríklad pred/po).*
  - *Príklad: Spotreba RAM na tom istom serveri: pred optimalizáciou a po optimalizácii kódu.*
- Nezávislé (nepárové) testy
  - *Význam: Testujeme dve rôzne, nesúvisiace vzorky.*
  - *Príklad: Porovnanie chybovosti dvoch rôznych výrobných liniek (A a B).*

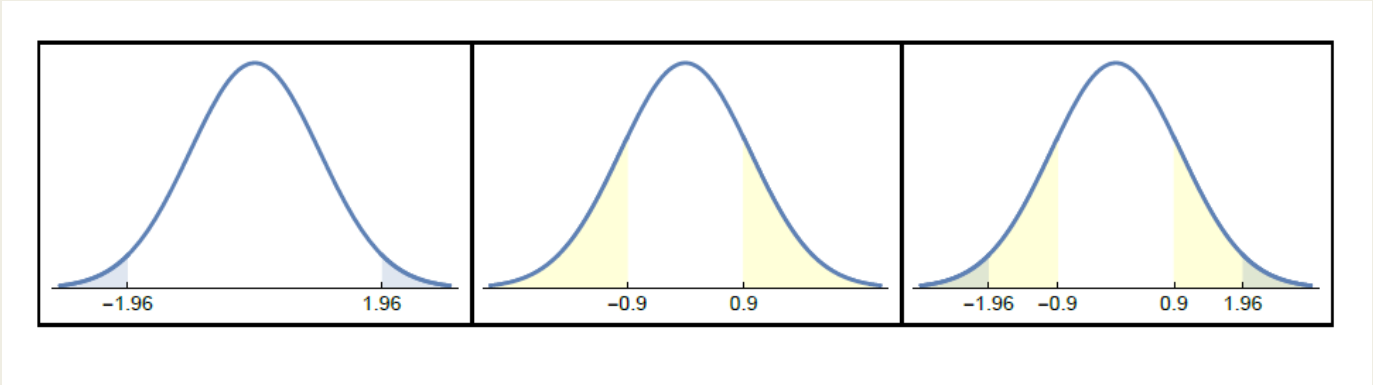
Rozdelenie testov podľa predpokladov o rozdelení

- Parametrické testy
  - *Význam: Vyžadujú konkrétne (zvyčajne normálne) rozdelenie dát.*
  - *Príklad: Porovnanie priemernej presnosti dvoch modelov, ak dáta kopírujú Gaussovu krivku.*
- Neparametrické testy
  - *Význam: Nevyžadujú žiadne predpoklady o rozdelení, pracujú s poradiami alebo silne zošikmenými dátami.*
  - *Príklad: Porovnanie dôležitosti (ranking) features v dvoch AI modeloch podľa ich poradia, nie presných čísel.*

Vyhodnotenie testu pomocou P hodnoty

- Test vyhodnotíme pomocou P −hodnoty (pravdepodobnostná hodnota, Probability Value), ktorú porovnávame s hladinou významnosti α(najčastejšie $\alpha = 0{,}05$).
- P −hodnota $\leq \alpha$
  - *Rozhodnutie: Zamietame H_0.*
  - *Záver: Rozdiel je štatisticky významný (reálny efekt/preukázaná zmena).*
- P −hodnota $> \alpha$
  - *Rozhodnutie: Nezamietame H_0.*
  - *Záver: Rozdiel nie je štatisticky významný (šum/náhoda).*

Výpočet P-hodnoty



- Testujeme hypotézu o strednej hodnote pri známej disperzii

  $H_0 \quad \mu = \mu_0 \qquad H_1 \quad \mu \neq \mu_0$

- $\alpha = 0{,}05$, kritická hodnota $u_{0{,}975} = 1{,}96$, štatistika $Z = 0{,}9$.
- P −hodnota = $P(|Z| \geq 0{,}9)$*(súčet plôch oboch chvostov za hranicami* $\pm 0{,}9$*).*

Test pre strednú hodnotu (známa disperzia, veľká vzorka)

- Testovacia štatistika a jej rozdelenie

$$Z = T_n = \frac{\bar{x} - \mu_0}{\sigma}\sqrt{n} \sim N(0,1)$$

Alternatíva H_1	Kritérium pre zamietnutie H_0	Kritérium pre nezamietnutie H_0 $P\ hodnota > \alpha$
$Obojstranná$	$\lvert Z\rvert \geq u\left(1 - \frac{\alpha}{2}\right)$	$\lvert Z\rvert < u\left(1 - \frac{\alpha}{2}\right)$
$Jednostranná$ $\mu > \mu_0$	$Z \geq u(1-\alpha)$	$Z < u(1-\alpha)$
$Jednostranná$ $\mu < \mu_0$	$Z \leq -u(1-\alpha)$	$Z > -u(1-\alpha)$

Príklad, čas strávený na webe

- $X = \{48, 55, 51, 62, 53, 58, 60, 50, 49, 57, 52, 61, 54, 56, 59, 53, 50, 58, 55, 53\}, n = 20;$ $\sigma = 3{,}8;\ \bar{X} = 54{,}7;\ u(0{,}95) = 1{,}64$
- Na hladine významnosti $\alpha = 0{,}05$ testujte hypotézu, že používateľ strávi na stránke aspoň 58 sekúnd.

H_0: $\mu = 58$ $\qquad$ H_1 (čo chceme dokázať): $\mu > 58$

$$Z = \frac{54{,}7 - 58}{3{,}8}\sqrt{20} = -3{,}88 < 1{,}64$$

- Záver: Hypotézu H_0 nezamietame, používatelia nestrávia na stránke viac ako 58 sekúnd.

Test pre strednú hodnotu, známa disperzia

- Testovacia štatistika a jej rozdelenie (Studentovo t rozdelenie s parametrom $(n-1)$ stupňov voľnosti)

$$T_n = \frac{\bar{x} - \mu_0}{s_x}\sqrt{n} \sim t_{n-1}$$

Alternatíva H_1	Kritérium pre zamietnutie H_0	Kritérium pre nezamietnutie H_0 $P\ hodnota > \alpha$
$Obojstranná$	$\lvert T_n \rvert \geq t_{n-1}\left(1 - \frac{\alpha}{2}\right)$	$\lvert T_n \rvert < t_{n-1}\left(1 - \frac{\alpha}{2}\right)$
$Jednostranná$ $\mu > \mu_0$	$T_n \geq t_{n-1}(1-\alpha)$	$T_n < t_{n-1}(1-\alpha)$
$Jednostranná$ $\mu < \mu_0$	$T_n \leq -t_{n-1}(1-\alpha)$	$T_n > -t_{n-1}(1-\alpha)$

Príklad, čas strávený na webe, neznáma disperzia

- $X = \{48, 55, 51, 62, 53, 58, 60, 50, 49, 57, 52, 61, 54, 56, 59, 53, 50, 58, 55, 53\}, n = 20;\ \bar{X} = 54{,}7;\ u(0{,}95) = 1{,}64; s_x = 4{,}105; t_{19}(0{,}95) = 1{,}73$

H_0: $\mu = 58$ H_1 (čo chceme dokázať): $\mu > 58$

$$Z = \frac{54{,}7 - 58}{3{,}8}\sqrt{20} = -3{,}88 < 1{,}73$$

- Záver: Hypotézu H_0 nezamietame, používatelia nestrávia na stránke viac ako 58 sekúnd.

Test o disperzii normálneho rozdelenia

- Tvar testovacej štatistiky a jej rozdelenie (nesymetrické)

$$T_n = \frac{(n-1){s_x}^2}{\sigma_0^2} \sim \chi^2_{n-1}$$

Alternatíva H_1	Kritérium pre zamietnutie H_0	Kritérium pre nezamietnutie H_0 $P\ hodnota > \alpha$
$Obojstranná$ $\sigma^2 \neq \sigma_0^2$	$T_n \leq \chi^2_{n-1}\left(\frac{\alpha}{2}\right)$ $alebo$ $T_n \geq \chi^2_{n-1}\left(1-\frac{\alpha}{2}\right)$	$\chi^2_{n-1}\left(\frac{\alpha}{2}\right) \leq T_n \leq \chi^2_{n-1}\left(1-\frac{\alpha}{2}\right)$
$Jednostranná$ $\sigma^2 > \sigma_0^2$	$T_n \geq \chi^2_{n-1}(1-\alpha)$	$T_n < \chi^2_{n-1}(1-\alpha)$
$Jednostranná$ $\sigma^2 < \sigma_0^2$	$T_n \leq \chi^2_{n-1}(\alpha)$	$T_n > \chi^2_{n-1}(\alpha)$

Test o disperzii normálneho rozdelenia

- Overte tvrdenie o disperzii $(\sigma^2 = 3{,}8^2)$,na hladine významnosti $\alpha = 0{,}1$.
  $X = \{48, 55, 51, 62, 53, 58, 60, 50, 49, 57, 52, 61, 54, 56, 59, 53, 50, 58, 55, 53\}$
- $n = 10; s_x^2 = 4{,}105^2; \sigma_0^2 = 3{,}8^2; \alpha = 0{,}1;\ \chi^2_{20-1}\left(\frac{0{,}1}{2}\right) = 10{,}11; \chi^2_{n-1}\,(0{,}95) = 30{,}14;$

$$T_n = \frac{19\,.\,4{,}105^2}{3{,}8^2} = 22{,}17; 10{,}11 < 22{,}17 < 30{,}14$$

- Tvrdenie o disperzii nezamietame na príslušnej hladine významnosti.

Dvojvýberové testy (parametre normálneho rozdelenia)

- Porovnanie parametrov dvoch súborov a vyhodnotenie štatistickej významnosti ich rozdielu. Výber správneho testu závisí od závislosti vzoriek:
- Nezávislé výbery (*Independent Samples*): Vzorky sú navzájom nezávislé (každé pozorovanie patrí inému objektu).
  - *Príklad: Porovnanie miery kliknutí (CTR) pre dva rôzne bannery (A vs. B) na webe.*
- Závislé / Párové výbery (*Dependent / Paired Samples*): Pozorovania v oboch výberoch sú navzájom párované (týkajú sa toho istého objektu).
  - *Príklad: Pred a po: Meranie stavu účastníka pred a po intervencii, liečbe alebo tréningu. Párové porovnanie: Dve metódy alebo podmienky na tom istom jedincovi (napr. ľavá vs. pravá ruka, metóda A vs. B)*

Párové testy, transformácia na jeden výber

- Redukcia na jednorozmerný súbor: Pre každý pár meraní (X_{1i}, X_{2i}) vypočítame rozdielové skóre (*Difference Score*):

$$D_i = X_{1i} - X_{2i}$$

- Formulácia hypotézy: Testujeme hypotézu o nulovom (alebo δ) priemernom rozdiele:

$$H_0: \mu_D = 0(\delta) \quad \text{(oproti rôznym alternatívam } H_1)$$

- Hlavný prínos:
  - *Eliminácia individuálnej variability medzi objektmi.*
  - *Zisťuje sa, či intervencia/podmienka spôsobila systémovú a konzistentnú zmenu nezávisle od prirodzených rozdielov medzi jednotlivcami.*

Príklad, porovnanie NLP modelov

- Zadanie: Porovnanie dvoch modelov (štandardný A vs. vyladený B) na 8 rovnakých videosekvenciách. Metrika: Kvalita výstupu meraná pomocou BLEU skóre.
- Testujte, či je priemerný rozdiel v kvalite nulový $(\mathrm{H}_0: \mu_\mathrm{D} = 0)$ oproti obojstrannej alternatíve, že rozdiel medzi modelmi existuje $(\mathrm{H}_1: \mu_\mathrm{D} \neq 0), \alpha = 0{,}05$.

model A	18,5	27,6	27,5	25	24,5	26,8	29,3	26,6
model B	18,58	27,45	27,27	24,64	24,1	26,33	29,33	26,63
rozdiel D	−0,08	0,15	0,23	0,36	0,4	0,47	−0,03	−0,03

- $\overline{D} = 0{,}18, \quad s_D = 0{,}215; \quad T = 2{,}42,; \quad t_7(0{,}975) = 2{,}36; \; Phodnota = 0{,}046, T > t_7(0{,}975),$ zamietame H_0, medzi modelmi existuje štatisticky významný rozdiel v kvalite generovaných titulkov.

Dvojvýberové testy pre nezávislé výbery

- Cieľ: Porovnať stredné hodnoty μ_X a μ_Y dvoch nezávislých populácií (rozsahy n_X, n_Y).

$$H_0: \mu_X - \mu_Y = \delta$$ (oproti rôznym alternatívam).

- Kľúčový krok: Pred výberom variantu t —testu musíme overiť rovnosť disperzií (rozptylov) oboch populácií.
- F-test rovnosti disperzií:

$$H_0: \sigma_X^2 = \sigma_Y^2 \qquad H_1: \sigma_X^2 \neq \sigma_Y^2$$

- Podľa výsledku testu použijeme
  - *Welchov* t —*test (nerovné rozptyly, heteroskedasticita)*
  - *Štandardný* t —*test (rovnaké rozptyly, homoskedasticita)*

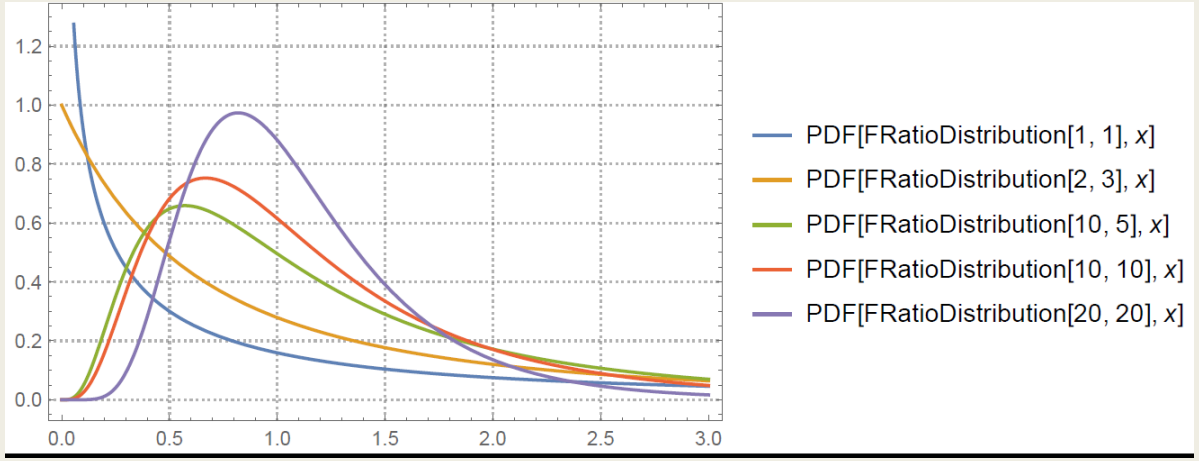
F –test rovnosti disperzií

- Testovacia štatistika (Fisherovo – Snedecorovo rozdelenie s parametra stupne voľnosti čitateľa a menovateľa, nesymetrické rozdelenie)

$$F = \frac{s_X^2}{s_Y^2} \sim F_{n_X-1, n_Y-1}$$

- Hypotézu o rovnosti disperzií nezamietame na hladine významnosti α, ak platí

$$F_{n_X-1, n_Y-1}(\frac{\alpha}{2}) < F < F_{n_X-1, n_Y-1}(1 - \frac{\alpha}{2})$$



F rozdelenie

Graf hustôt rozdelenia s rôznymi stupňami voľnosti

Welchov t – test (heteroskedasticita)

- Predpoklad: Dva nezávislé výbery rozsahov n_X, n_Y s neznámymi a rôznymi disperziami ($\sigma_X^2 \neq \sigma_Y^2$).

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_X^2}{n_X} + \frac{s_Y^2}{n_Y}}} \sim t_{df}$$

- Stupne voľnosti (df) – Welchov-Satterthwaitov vzťah:

$$df \approx \frac{\left(\frac{s_X^2}{n_X} + \frac{s_Y^2}{n_Y}\right)^2}{\frac{\left(\frac{s_X^2}{n_X}\right)^2}{n_X - 1} + \frac{\left(\frac{s_Y^2}{n_Y}\right)^2}{n_Y - 1}}$$

Welchov t — test (vyhodnotenie, implementácia)

- Výsledok zaokrúhľujeme nadol na najbližšie celé číslo. Menší počet stupňov voľnosti robí test obozretnejším voči zamietnutiu H_0, čím kompenzuje neistotu nerovných disperzií.
- Oblasť nezamietnutia H_0(obojstranná alternatíva):

$$|T| < t_{df}\left(1 - \frac{\alpha}{2}\right)$$

- Softvérová implementácia (R): Funkcia $t.test()$ je predvolene nastavená na Welchov t- test ($paired = FALSE, var.equal = FALSE$).

Welchov test, príklad

- Zadanie: Rozhodnutie medzi modulom A (starší, lacnejší, neistá stabilita/variabilita) a modulom B.
- Cieľ: Overiť štatisticky významný rozdiel v priemernej spotrebe pamäte, $\alpha = 0{,}05$.
- Vstupné dáta (spotreba v MB):

A	80	70	95	100	75	90
B	89	89	90	84	92	

- $n_X = 6;\ n_Y = 5;\ \bar{X} = 86{,}67; \bar{Y} = 88{,}8;\ s_X^2 = 166{,}67; s_Y^2 = 8{,}7;\ F = \frac{166{,}67}{8{,}7} = 19{,}16 > F_{5,4}(0{,}95) = 6{,}26$. Hypotézu o rovnosti disperzií zamietame na príslušnej hladine významnosti (ak $F > 1$, stačí porovnať iba s horným kvantilom).

Welchov test, príklad

- Štatistika pre Welchov test:

$$T = \frac{86{,}67 - 88{,}8}{\sqrt{\frac{166{,}67}{6} + \frac{8{,}7}{5}}} = -0{,}39$$

- Welchov-Satterthwaitov vzťah:

$$df \approx \frac{29{,}52^2}{\frac{27{,}78^2}{5} + \frac{1{,}74^2}{4}} = 5{,}62$$

- $|T| = 0{,}39 < t_5(0{,}95) = 2{,}57$. Nezamietame nulovú hypotézu. Aj napriek rozdielnej stabilite (rozptylu) nebol nájdený štatisticky významný rozdiel v priemernej spotrebe pamäte medzi modulom A a modulom B. Lacnejší modul A je štatisticky rovnako náročný na pamäť ako modul B, ale je výrazne menej stabilný (má oveľa vyšší rozptyl).

T – test za rovnosti rozptylov

- Združený (*pooled*) rozptyl: Predpokladá rovnosť disperzií. Výberové rozptyly združujeme do spoločného váženého priemeru (*pooled variance*):

$$s_p^2 = \frac{(n_X - 1)s_X^2 + (n_Y - 1)s_Y^2}{n_X + n_Y - 2}$$

- Testovacia štatistika a jej rozdelenie:

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{s_p^2\left(\frac{1}{n_X} + \frac{1}{n_Y}\right)}} \sim t_{n_X+n_Y-2}$$

- Oblasť nezamietnutia H_0(obojstranná alternatíva):

$$|T| < t_{n_X+n_Y-2}\left(1 - \frac{\alpha}{2}\right)$$