ANOVA
ANALÝZA ROZPTYLU

ANOVA

- Úloha: Porovnať stredné hodnoty viacerých skupín a nájsť štatisticky významné rozdiely
- Voľba testu:
  - 2 *výbery: Dvojvýberový* t —*test.*
  - 3 *a viac výberov: ANOVA (analýza rozptylu).*
- Výhoda ANOVA: Testuje zhodu priemerov všetkých skupín naraz.
- Nevýhody použitia viacerých *t* —testov naraz
  - *Opakované testovanie t-testom drasticky zvyšuje riziko chyby prvého druhu.*
  - *ANOVA minimalizuje riziko chybného zamietnutia nulovej hypotézy* (H_0).

ANOVA, kvalitatívna premenná

- Rola kvalitatívnej premennej (faktora):
  - *Rozdeľuje dáta do jasne definovaných skupín.*
- Príklad:
  - *Faktor (skupiny): Typ operačného systému (Win / Mac / Linux).*
  - *Meraná premenná: Priemerná spotreba pamäte v MB.*
  - *Cieľ: Zistiť, či typ systému štatisticky významne ovplyvňuje spotrebu pamäte*
- Predpoklady (podmienky) ANOVA:
  - *Normálne rozdelenie dát v každej sledovanej skupine.*
  - *Homogenita rozptylov (rovnaká variabilita dát vo všetkých skupinách).*

ANOVA, podmienky ANOVA

- Možnosti pri nesplnení predpokladu ANOVA
- Neparametrická metóda (Kruskalov-Wallisov test):
  - *Použitie pri porušenej normalite /silnom zošikmení.*
  - *Analyzuje dáta na základe poradia (rangov) namiesto priamych hodnôt.*
- Robustná parametrická metóda (Welchova ANOVA):
  - *Použitie pri zachovanej normalite, ale nerovnakých rozptyloch.*
- Transformácia dát:
  - *Aplikácia matematickej funkcie (napr. logaritmus, odmocnina) na splnenie predpokladov pre klasickú ANOVA.*

ANOVA, podmienky ANOVA

- Postup overovania podmienok ANOVA:
- Vizuálna analýza:
  - *Kontrola dát (boxploty, histogramy) pre každú skupinu zvlášť.*
- Overenie normality:
  - *Testuje sa buď v každej triede (skupine) zvlášť, alebo prostredníctvom rezíduí modelu.*
- Overenie homogenity rozptylov:
  - *Testuje sa rovnaká variabilita dát naprieč všetkými porovnávanými skupinami (napr. Leveneovým testom).*

ANOVA, nevyvážený dizajn

- Majme I nezávislých skupín (úrovní faktora). Každé meranie označme Y_{ij} (i je index skupiny a j je index merania v danej skupine, $i = 1, \dots, I,\ j = 1, \dots, n_i$).
- Celkový počet pozorovaní je $n = n_1 + \cdots + n_I$ (nevyvážený dizajn = skupiny môžu mať rôzny počet prvkov n_i).
- Dáta v každej skupine pochádzajú z normálneho rozdelenia s vlastnou strednou hodnotou μ_i a spoločným rozptylom σ^2:
  - *Skupina 1:* $Y_{11}, Y_{12}, \dots, Y_{1n_1} \sim N(\mu_1, \sigma^2)$
  - *Skupina 2:* $Y_{21}, Y_{22}, \dots, Y_{2n_2} \sim N(\mu_2, \sigma^2)$
  - …
  - *Skupina I:* $Y_{I1}, Y_{I2}, \dots, Y_{In_I} \sim N(\mu_I, \sigma^2)$

Jednofaktorová analýza rozptylu, One Way ANOVA

- Cieľ: Zistiť, či úroveň jedného faktora (triediaceho znaku) signifikantne ovplyvňuje hodnoty kvantitatívnej premennej (priemery skupín).
- Princíp: Skúmané merania sú rozdelené do skupín na základe jediného triediaceho znaku.
- Úloha: Testovanie rovnosti stredných hodnôt (priemerov) medzi všetkými úrovňami daného faktora.
- Nulová hypotéza (H_0): Priemery všetkých skúmaných skupín sú rovnaké.

$$H_0: \mu_1 = \mu_2 = \cdots = \mu_I$$

- Alternatívna hypotéza (H_1): Aspoň jedna skupina sa svojim priemerom líši od ostatných.

$$H_1: \exists\, i, j \quad \text{také, že} \quad \mu_i \neq \mu_j$$

Jednofaktorová analýza rozptylu

- Štatistický model: Vplyv jedného faktora na náhodnú premennú Y je definovaný vzťahom:

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$

- Komponenty modelu:
  - μ: *Celkový (populačný) priemer.*
  - α_i: *Efekt i-tej úrovne faktora (rozdiel medzi priemerom i-tej skupiny a celkovým priemerom μ).*
  - ε_{ij}: *Náhodná chyba merania.*
- Predpoklady modelu: Klasická ANOVA je založená na základných predpokladoch o chybovom člene:

$$\varepsilon_{ij} \sim N(0, \sigma^2)$$

Tvar testovanej hypotézy pomocou efektov

- Prechod na model: Vyjadrenie pôvodných hypotéz prostredníctvom efektov deliaceho faktora (α_i).
- Nulová hypotéza (H_0): Všetky efekty faktora sú nulové (priemery sú rovnaké).

$$H_0: \alpha_1 = \alpha_2 = \cdots = \alpha_I = 0$$

- Alternatívna hypotéza (H_1): Aspoň jeden efekt faktora je nenulový (aspoň jeden priemer sa líši).

$$H_1: \exists\, i \quad \text{také, že} \quad \alpha_i \neq 0$$

- Podstata testu: ANOVA overuje rovnosť stredných hodnôt porovnávaním dvoch rôznych zdrojov rozptylu v dátach.

ANOVA, rozklad celkového rozptylu

- Základná myšlienka spočíva v rozklade celkového rozptylu $S_T$na dve samostatné zložky: $S_T = S_A + S_E$
- Celkový rozptyl S_T (Celková variabilita všetkých dát okolo celkového priemeru $\bar{Y}$):

$$S_T = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(Y_{ij} - \bar{Y}\right)^2$$

- S_A– Rozptyl medzi skupinami (systematický rozptyl), Meria variabilitu medzi priemermi jednotlivých skupín ($\bar{Y}_i$) a celkovým priemerom ($\bar{Y}$).

$$S_A = \sum_{i=1}^{I} n_i \, (\bar{Y}_i - \bar{Y})^2$$

- Význam:
  - *Ak platí H_0(priemery sú rovnaké), hodnota S_A je malá.*
  - *Ak platí H_1(priemery sú rôzne), hodnota S_A je veľká.*

ANOVA, rozklad celkového rozptylu

- Reziduálny (vnútro skupinový) rozptyl S_E, variabilita *vo vnútri* jednotlivých skupín

$$S_E = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(Y_{ij} - \bar{Y}_i\right)^2$$

- Vlastnosti a funkcia v teste
  - *Charakteristika merania: Vyjadruje mieru kolísania jednotlivých meraní v rámci jednej skupiny (predstavuje chybu merania a náhodnú variabilitu).*
  - *Nezávislosť: Je nezávislý od toho, či je vplyv sledovaného faktora významný.*
  - *Referenčná úloha: Slúži ako základné meradlo náhodnej chyby, proti ktorému ANOVA testuje vplyv faktora (S_A).*

ANOVA, rozklad celkového rozptylu, príklad

- Príklad: Objem úrody troch rôznych druhov hnojiva (skupiny A, B, C).
- Rozptyl S_A (medzi skupinami): Meria rozdiely medzi priemernými úrodami jednotlivých hnojív. Ak jedno hnojivo výrazne zaberie, S_A je veľký.
- Rozptyl S_E(vo vnútri skupín): Predstavuje prirodzenú náhodnú variabilitu (napr. vplyv tieňa či vody na rastliny s *rovnakým* hnojivom). Slúži ako referenčný štandard.
- Rozhodovacie kritérium:
  - $S_A \gg S_E$ →*rozdiel prevyšuje náhodný šum →faktor má reálny vplyv.*
  - $S_A \approx S_E$ →*rozdiely sú dôsledkom iba náhodného kolísania.*

```
anova <- aov(new_data$mprij~vzdelanie)
summary.aov(anova)
```

```
##             Df  Sum Sq Mean Sq F value   Pr(>F)
## vzdelanie    2 2835237 1417618   33.72 1.84e-09 ***
## Residuals   42 1765513   42036
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Jednofaktorová ANOVA

- Testovacia štatistika je v tvare

$$F = \frac{\frac{S_A}{I-1}}{\frac{S_E}{n-I}} \sim F_{I-1,n-I}$$

- Vlastnosti štatistiky F: Za platnosti H_0 je $F \approx 1$. Ak H_0 neplatí, F nadobúda hodnoty výrazne väčšie ako 1.
- Všetky charakteristiky sú uvedené v tabuľke analýzy rozptylu, ktorá je bežným výstupom štatistických softvérov.

Jednofaktorová ANOVA

- Tabuľka ANOVA

zdroj variability	stupne voľnosti	súčet štvorcov	rozptyl	F štatistika	P hodnota
riadková	$I-1$	S_A	$s_a^2 = \frac{S_A}{I-1}$	$F = \frac{s_a^2}{s_e^2}$	$Phodnota$
reziduálna	$n-I$	S_E	$s_e^2 = \frac{S_E}{n-I}$		

- Hypotézu H_0 o nulovosti faktora (faktor je štatisticky nevýznamný) zamietame na hladine významnosti α ak $F \geq F_{I-1,n-I}(1-\alpha)$ alebo P $hodnota \leq \alpha$.

Post – hoc testy

- Ak ANOVA potvrdí štatisticky významný rozdiel medzi skupinami, post-hoc testy identifikujú, ktoré konkrétne dvojice tried sa od seba navzájom líšia.
- Hlavné typy testov:
  - *Tukeyho HSD test (Honestly Significant Difference): Najpoužívanejší test pri splnení predpokladov ANOVA (normalita a homogenita rozptylov). Kontroluje celkovú chybovú mieru (FWER – Family-wise Error Rate).*
  - *Games-Howell test: Alternatíva vhodná po Welchovej ANOVA v prípade porušenia homogenity rozptylov.*

Post test

- Tukeyho test: Využíva kritické hodnoty studentizovaného rozpätia $q_{I,n-I}(\alpha)$.
- Podmienka zamietnutia nulovej hypotézy (H_0) o rovnosti stredných hodnôt pre výbery ia j:

$$|\bar{Y}_i - \bar{Y}_j| > \frac{S_E}{n-I}\, q_{I,n-I}(\alpha) \sqrt{\frac{1}{2}\left(\frac{1}{n_i} + \frac{1}{n_j}\right)}$$

- Scheffeho test: Konzervatívnejší test (menej často zamieta nulovú hypotézu). Použitie: Keď chceme minimalizovať pravdepodobnosť falošne pozitívnych výsledkov (chyby I. typu).

Miera efektu, Efect Size

- Štatistická vs. praktická významnosť: Post-hoc testy určujú, *či* existuje rozdiel, miera efektu meria, *aký je veľký*.
- Nezávislosť od veľkosti vzorky: Odhaľuje skutočnú silu účinku – predchádza chybnej interpretácii pri veľkých vzorkách, kde aj zanedbateľný rozdiel vychádza ako štatisticky významný.
- Porovnateľnosť: Umožňuje štandardizované porovnanie výsledkov naprieč rôznymi štúdiami.
- Praktická hodnota: Určuje, či má zistený efekt reálny dopad v praxi.

Miera efektu

- Eta-kvadrát (η^2): Vyššia hodnota znamená väčší efekt (hodnoty medzi 0 a 1) tendencia nadhodnocovať skutočný efekt.

$$\eta^2 = \frac{S_A}{S_T}$$

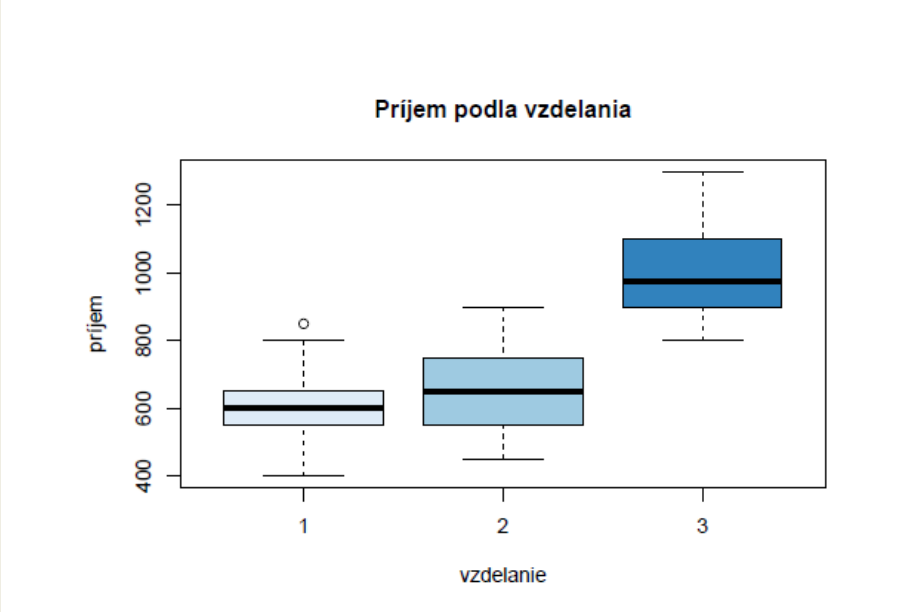
- Parciálny Eta-kvadrát (η_p^2): Pre viacfaktorovú ANOVA (vzorec napríklad pre faktor A); z menovateľa vylučuje rozptyl iných faktorov.

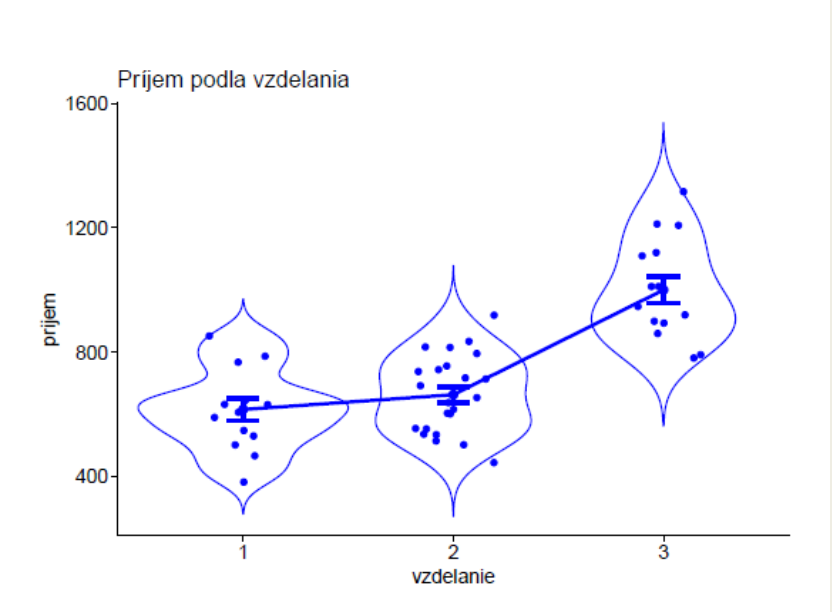
$$\eta^2 = \frac{S_A}{S_A + S_E}$$

- Omega-kvadrát (ω^2): Menej nadhodnotený (konzervatívnejší) odhad, preferovaný pri zovšeobecňovaní na populáciu.

Miera efektu

- Interpretácia číselných hodnôt pre tieto miery efektu, ktoré vyjadrujú podiel vysvetlenej variability (v percentách):
  - $\approx 0{,}01$*(1 %): Malý efekt, faktor vysvetľuje len minimum rozdielov; v praxi ide o slabý, často zanedbateľný vplyv.*
  - $\approx 0{,}06$ *(6 %): Stredný efekt, stredne silný vplyv, ktorý je už bežne postrehnuteľný a reálne viditeľný.*
  - $\geq 0{,}14$*(14 % a viac): Veľký efekt, silný a dominantný vplyv daného faktora na celkový výsledok.*





ANOVA, vizualizácia

Dvojfaktorová analýza rozptylu

- Dvojfaktorová analýza rozptylu: Súčasné skúmanie vplyvu dvoch rôznych faktorov na sledovanú premennú.
- *Praktické* príklady:
  - *Medicína: Vek pacienta (faktor 1) × Typ podaného lieku (faktor 2).*
  - *Poľnohospodárstvo: Druh pšenice (faktor 1) × Typ pôdy (faktor 2).*
  - *IT / Web: Typ databázy (faktor 1) × Umiestnenie servera (faktor 2).*
- Hlavný prínos: Umožňuje zistiť nielen samostatný vplyv každého faktora, ale aj ich vzájomnú interakciu.

Dvojfaktorová ANOVA bez interakcií

- Sleduje vplyv dvoch faktorov na závislú premennú za predpokladu, že ich účinky sú aditívne (nezávislé, navzájom sa nemusia ovplyvňovať).
- Predpoklady: Platnosť normality dát a rovnosti disperzií v triedach.
- Matematický model:

$$Y_{ijp} = \mu + \alpha_i + \beta_j + \varepsilon_{ijp}$$

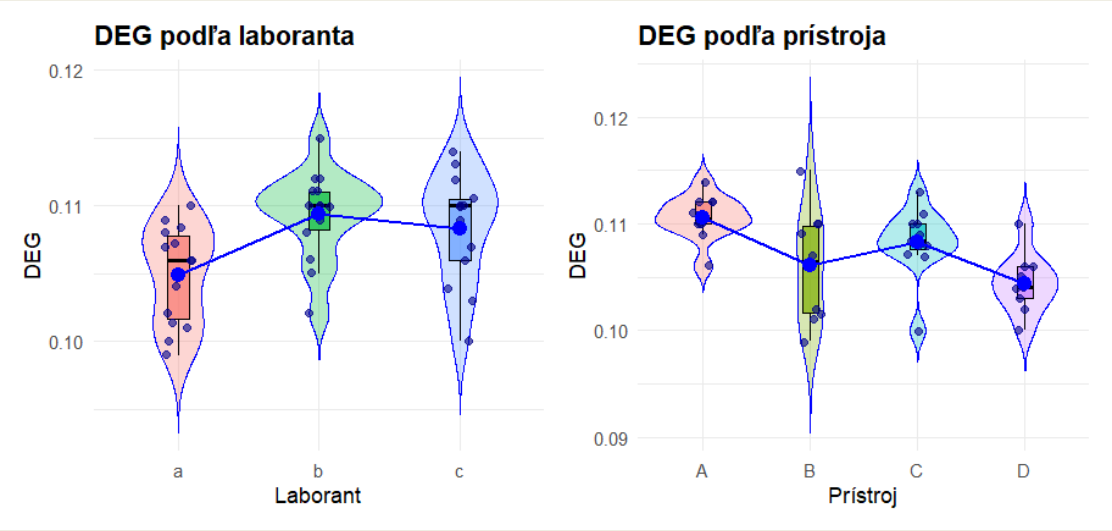
  - α_i *(faktor* A *s* I *úrovňami),*
  - β_j *(faktor* B *s* J *úrovňami)*
  - $\varepsilon_{ijp} \sim N(0, \sigma^2)$ *– nezávislé náhodné chyby*

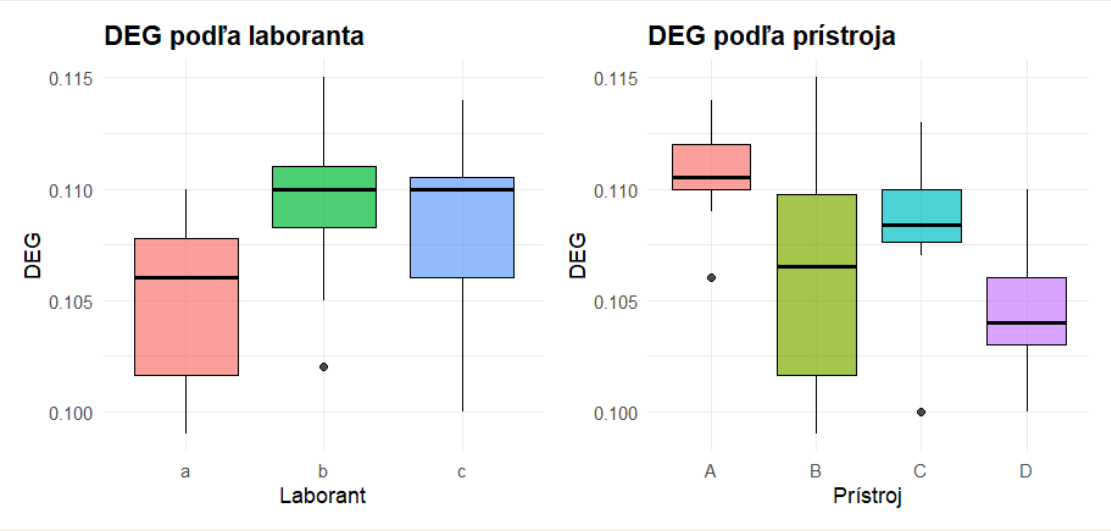
Dvojfaktorová analýza rozptylu bez interakcií

- Nulové hypotézy (bez vplyvu faktorov):
  - (faktor A) $H_0: \alpha_1 = \cdots = \alpha_I = 0$ vs. $H_1: \exists i, \alpha_i \neq 0$
  - (faktor B) $H_0: \beta_1 = \cdots = \beta_J = 0)$ vs. $H_1: \exists j, \beta_j \neq 0$
- Rozklad celkovej variability:

$$S_T = S_A + S_B + S_E$$

- *(Celková variabilita = Faktor A + Faktor B + Reziduálna/Chybová)*
- Všetky testovacie štatistiky a výsledky sa uvádzajú v štandardnej ANOVA tabuľke. Pribúda riadok pre každý ďalší faktor, obsahujúci základné charakteristiky. Vyhodnotenie: napríklad podľa P hodnoty.





ANOVA, vizualizácia

- Traja laboranti (faktor laborant) vykonali opakované merania diethylenglykolu (DEG) na štyroch chromatografoch (faktor prístroj). Má na výsledky vplyv laborant (faktor A)? Použitý prístroj (faktor B)?
- Krabicové a husľové grafy pre každý faktor zvlášť.

Dvojfaktorová ANOVA s interakciami

- Účinok jedného faktora závisí od úrovne druhého (efekty sa nesčítavajú, ale vzájomne násobia či rušia). Praktický význam: Najčastejšie používaná verzia v reálnej praxi, keďže interakcie faktorov sú bežné.
- Matematický model:

$$Y_{ijp} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijp}$$

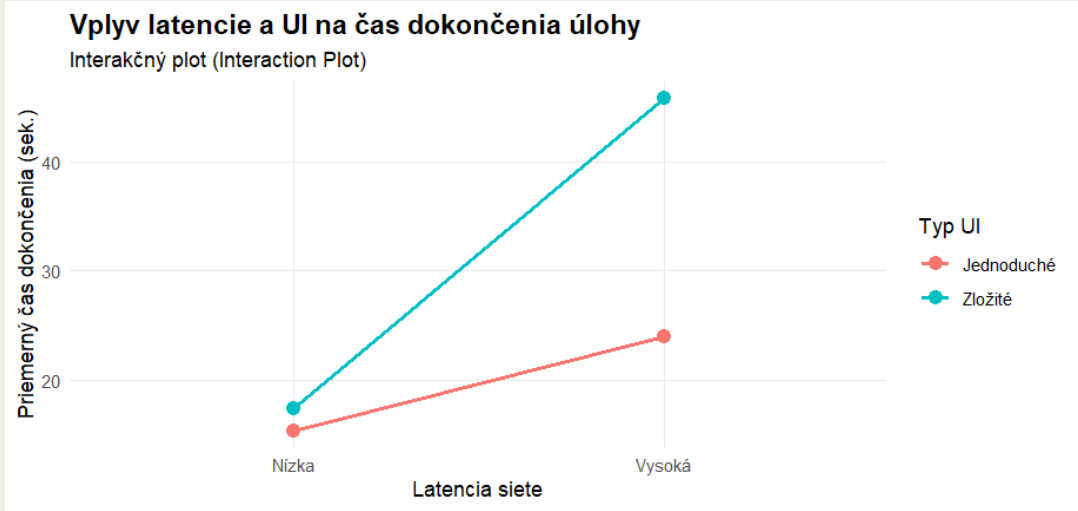
  - $(\alpha\beta)_{ij}$ – *interakčný člen pre faktory* $A(i = 1, \dots, I)$ *a* $B(j = 1, \dots, J)$.
- Testovaná hypotéza:

$H_0: (\alpha\beta)_{ij} = 0$ pre všetky i, j (žiadna interakcia) $H_1: \exists\, i, j$ tak, že $(\alpha\beta)_{ij} \neq 0$

- Pravidlo interpretácie: Ak je interakcia štatisticky významná, hlavné účinky faktorov sa samostatne neinterpretujú.

Vizualizácia

- Interaction Plot je nevyhnutný nástroj na vizuálne overenie tvaru a významnosti vzájomného pôsobenia faktorov.
- Testovanie rýchlosti a použiteľnosti e-shopu. Sledujeme spracovanie požiadavky (čas) v závislosti od dvoch faktorov (A — latencia siete, B – zložitosť používateľského rozhrania).
- Pri nízkej latencii: Časy dokončenia úlohy sú pre oba typy rozhraní (jednoduché aj zložité) takmer identické a minimálne.
- Pri vysokej latencii: Nastáva zásadný rozdiel – pri zložitom UI čas prudko narastá (strmá čiara), kým jednoduché UI zvláda vysokú latenciu oveľa odolnejšie.
- Záver interakcie: Vplyv latencie siete výrazne závisí od zložitosti UI. Graf vizuálne potvrdzuje silnú interakciu medzi oboma faktormi.



Testy rovnosti rozptylov

- Cieľ: Zistiť, či majú skupiny rovnaký rozptyl (homogenita rozptylov /homoskedasticita).

  H_0: Rozptyly skupín sú rovnaké. H_1: Aspoň jedna skupina má iný rozptyl.

- Bartlettov test: Normálne rozdelené dáta
- Leveneho test: Zvyčajne ak dáta nie sú normálne rozdelené. Pre reálne dáta (ekonómia, biologické a sociálne vedy) a ako prvá voľba v softvéroch (SPSS, R, Python).

Testy rovnosti rozptylov

Kritérium	Bartlettov test	Leveneho test
Princíp výpočtu	Logaritmy rozptylov skupín	Absolútne odchýlky od priemeru/mediánu
Citlivosť na normalitu	Vysoká (vyžaduje presne normálne dáta)	Nízka (odolný voči odchýlkam od normality)
Citlivosť na vybočujúce hodnoty	Veľmi citlivý	Málo citlivý (hlavne vo verzii s mediánom)
Praktické využitie	Špecifické (ideálne laboratórne podmienky)	Štandard pre reálne dáta v praxi

Testy rovnosti rozptylov

- **Bartlettov test:**
- Len ak máte **potvrdené normálne rozdelenie dát** (napr. cez Shapiro-Wilk test).
- **Leveneho test:**
- Ak dáta **nie sú normálne** alebo si normalitou nie ste istí.
- Pre reálne dáta (ekonómia, biologické a sociálne vedy) a ako **prvá voľba v softvéroch (SPSS, R, Python)**.

Test rovnosti roztylov, Bartlettov

- Pred samotnou analýzou treba overiť podmienky normality výberov a podmienku rovnosti disperzií

$$H_0 \ \sigma_1^2 = \sigma_2^2 = \cdots = \sigma_I^2$$

- Bartlettov parametrický test (citlivý na porušenie normality)

$$s_e^2 = \frac{S_E}{n-I} \text{ a } s_i^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} \left(Y_{ij} - \overline{Y}_i\right)^2$$

$$A = 1 + \frac{1}{3(I-1)} \left(\sum_{i=1}^{I} \frac{1}{n_i - 1} - \frac{1}{n-I} \right)$$

$$T = \frac{1}{A} \left[(n-I) \ln s_e^2 - \sum_{i=1}^{I} (n_i - 1) \ln s_i^2 \right]$$

- T má približne χ^2_{I-1} rozdelenie, hypotézu H_0 zamietame na hladine významnosti α, ak $T \geq \chi^2_{I-1}(1-\alpha)$

Test rovnosti rozptylov, Leveneov

- Leveneov neparametrický test, menej citlivý na odchýlky od normality, ale môže mať menšiu silu najmä pri malých vzorkách

$$T = \frac{(n-I)\sum_{i=1}^{I} n_i (z_{i.} - z_{..})^2}{(I-1)\sum_{i=1}^{I}\sum_{j=1}^{n_i}\left(z_{ij} - z_{i.}\right)^2}$$

$$z_{ij} = \left|Y_{ij} - \overline{Y_i}\right|,\ z_{i.} = \frac{1}{n_i}\sum_{j=1}^{n_i} z_{ij},\ z_{..} = \frac{1}{n}\sum_{i=1}^{I}\sum_{j=1}^{n_i} z_{ij}$$

- Hypotézu H_0 zamietame na hladine významnosti α, ak $T \geq F_{I-1,n-I}(1-\alpha)$
- Ak vo vzorci pre z_{ij} nahradíme priemer v triede *i* mediánom, hovoríme o Brown-Forsythe teste